Detecção de anomalias em transações Ethereum: avaliação temporal de Autoencoder e Isolation Forest

Marcelo Corni Alves[1], **Saulo Moraes Villela**[1],
Heder Soares Bernardino[1], **Alex Borges Vieira**[1]

[1]Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal de Juiz de Fora (UFJF) – Juiz de Fora, MG, Brasil

marcelo.corni@estudante.ufjf.br, saulo.moraes@ufjf.br

heder.bernardino@ufjf.br, alex.borges@ufjf.br

Abstract. *We compare Autoencoder (AE) and Isolation Forest (IF) on 523.9 million Ethereum transactions from 2025 available in the AWS source using 21 on-chain features, previously selected hyperparameters, and thresholds calibrated in June. At Q99.5, during July–November, IF flags 757,192 transactions historically associated with MEV bots, compared with 544,738 for AE. Their intersection concentrates 36.70% associated transactions, while their union recovers 951,073. IF achieves higher Average Precision in every window, but AE concentrates more associated transactions in the top 1% of scores during December. The results distinguish overall ranking quality, temporal response, and investigation budgets, supporting prioritization policies with different investigation volumes.*

Resumo. *Comparamos Autoencoder (AE) e Isolation Forest (IF) em 523,9 milhões de transações Ethereum de 2025, disponíveis na fonte AWS, com 21 atributos on-chain, hiperparâmetros pré-selecionados e limiares calibrados em junho. Em Q99,5, no teste de julho a novembro, o IF sinaliza 757.192 transações historicamente associadas a bots MEV, contra 544.738 do AE. A interseção concentra 36,70% de associadas, e a união recupera 951.073. O IF obtém maior Average Precision em todos os recortes, mas o AE concentra mais associadas no topo de 1% dos escores em dezembro. Os resultados distinguem ordenação global, resposta temporal e orçamento de investigação, caracterizando políticas de priorização com diferentes volumes de investigação.*

1. Introdução

Monitorar a atividade da Ethereum envolve selecionar, entre milhões de operações diárias, transações que merecem investigação após sua execução. Transferências, contratos inteligentes e aplicações financeiras compartilham os mesmos blocos, mas diferem em consumo de gás, taxas, posição e recorrência dos participantes. Esses atributos permitem caracterizar desvios e organizar a triagem em um livro-razão distribuído. A ordenação também possui valor econômico: Daian et al. [Daian et al. 2020] documentam bots de arbitragem e competição por prioridade, e Torres et al. [Torres et al. 2021] investigam padrões de *front-running*. Escores de anomalia podem apoiar a escolha de operações para análise, articulando caracterização da rede e esforço de investigação.

O problema considerado é compreender como dois mecanismos não supervisionados de detecção respondem às mudanças temporais dessa atividade. Aplicar um corte fixo não garante um volume estável de sinalizações; combinar detectores também não informa, por si só, quais transações cada método acrescenta. Além disso, uma boa ordenação global pode coexistir com baixa concentração de operações de interesse nas primeiras posições do ranking. Essas diferenças são relevantes quando a capacidade de inspeção é restrita e a distribuição transacional muda ao longo do tempo.

Comparamos Autoencoder (AE) e Isolation Forest (IF) em 523.937.952 transações disponíveis na fonte AWS nos 365 dias de 2025, descritas pelos mesmos 21 atributos *on-chain*. Os modelos são ajustados de janeiro a abril, com hiperparâmetros escolhidos em estudo anterior, e os limiares são calibrados em junho e mantidos fixos. Investigamos três perguntas: **RQ1**, como o volume sinalizado responde aos diferentes recortes sob cortes congelados? **RQ2**, quanto os modelos concordam e quais são suas contribuições exclusivas? **RQ3**, como a ordenação global se relaciona à concentração de transações associadas a bots MEV sob um mesmo orçamento de análise?

A contribuição é uma caracterização temporal e operacional desses mecanismos na mesma população transacional. Farrugia et al. [Farrugia et al. 2020] classificam contas com atributos agregados, enquanto a literatura de *front-running* identifica relações estruturais entre operações. Aqui, a unidade é a transação executada; a comparação relaciona mudanças marginais, conjuntos compartilhados e exclusivos e decisões sob orçamento fixo. A associação histórica do remetente no Etherscan Label Cloud fornece uma referência auxiliar após a inferência. O estudo quantifica como as prioridades produzidas por reconstrução e isolamento divergem ao longo de 2025, sem tratar essa associação como confirmação de ataques individuais.

A Seção 2 situa essa comparação na literatura. A Seção 3 apresenta os dados e o protocolo; a Seção 4 responde às perguntas por meio das taxas, interseções e rankings. A Seção 5 sintetiza os achados e a continuidade da investigação.

2. Fundamentação e trabalhos relacionados

A literatura é organizada em três eixos: detecção de anomalias; atividade ilícita, *front-running* e MEV na Ethereum; e avaliação sob desbalanceamento e mudanças temporais. A Figura 1 apresenta o fluxo de leitura e síntese, que compara unidades de análise, atributos, rótulos e objetivos dos estudos.

Quanto aos mecanismos de detecção, Sakurada e Yairi [Sakurada and Yairi 2014] investigam autoencoders para detecção de anomalias por redução não linear de dimensionalidade, em dados artificiais e telemetria. O erro de reconstrução mede o afastamento de uma observação da representação aprendida e fundamenta o escore transacional do AE neste estudo.

Liu et al. [Liu et al. 2008] propõem o Isolation Forest, que constrói árvores aleatórias sobre subamostras e associa caminhos médios curtos a observações mais facilmente isoladas. Reconstrução e isolamento produzem escores com escalas distintas; sua aplicação à mesma população permite comparar conjuntos priorizados pelos dois mecanismos.

Na análise da Ethereum, Farrugia et al. [Farrugia et al. 2020] classificam contas Ethereum com XGBoost, utilizando 42 atributos e 4.681 contas, das quais 2.179 rotuladas

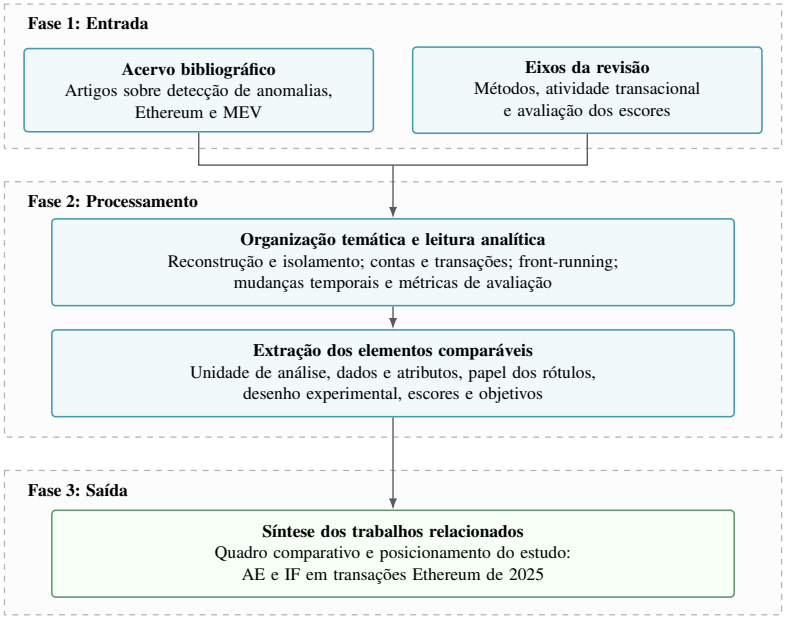


Figura 1. Fluxograma de organização e análise da literatura utilizada nos trabalhos relacionados.

como ilícitas. A agregação do histórico caracteriza a conta; a unidade transacional adotada aqui permite examinar operações individuais de um mesmo remetente.

Podgorelec et al. [Podgorelec et al. 2020] incorporam detecção personalizada de anomalias à assinatura automatizada de transações Ethereum. O perfil individual orienta uma decisão anterior à assinatura, enquanto nosso protocolo examina operações executadas e seu contexto intrabloco.

Daian et al. [Daian et al. 2020] relacionam bots de arbitragem e *priority gas auctions* à extração de valor pela ordenação transacional. Eskandari, Moosavi e Clark [Eskandari et al. 2020] sistematizam *front-running* em deslocamento, inserção e supressão, padrões investigados empiricamente na Ethereum por Torres et al. [Torres et al. 2021]. Esses trabalhos fornecem o contexto econômico e estrutural para interpretar operações priorizadas pelos detectores.

Heimbach et al. [Heimbach et al. 2023] analisam a *proposer-builder separation*, distinguindo construção e proposição dos blocos. Essa organização contextualiza a interpretação conjunta de taxas, posição e contexto transacional na atividade associada a MEV.

Zhang et al. [Zhang et al. 2024] classificam categorias de *front-running*, e Li et al. [Li et al. 2024] integram ao Geth a detecção de ataques *sandwich*. O Mecon de Yao et al. [Yao et al. 2025] usa grafos centrados em endereços para classificar atividade MEV. Naik et al. [Naik et al. 2026] comparam a concordância e o custo de heurísticas de detecção de categorias MEV. Em triagem pós-execução, Chaudhary et al. [Chaudhary et al. 2026] usam LightGBM e rótulos derivados de heurísticas para transações multisig, com validação temporal por altura de bloco. A Tabela 1 situa essas abordagens em relação à unidade e ao objetivo deste trabalho.

Tabela 1. Posicionamento do estudo em relação às abordagens aplicadas à Ethereum.

Trabalho	Unidade ou foco	Abordagem e relação com este estudo
[Farrugia et al. 2020]	Contas ilícitas	Classificação supervisionada por atributos agregados de contas e histórico.
[Podgorelec et al. 2020]	Assinatura de transações	Detecção personalizada associada à decisão de assinatura.
[Torres et al. 2021]	Padrões de front-running	Identificação empírica de inserção, deslocamento e supressão.
[Yao et al. 2025]	Endereços	Classificação de atividade MEV por grafos.
[Naik et al. 2026]	Heurísticas MEV	Concordância e custo de heurísticas por categoria.
[Chaudhary et al. 2026]	Transações multisig	Triagem pós-execução com LightGBM e validação temporal.
Este artigo	Transações individuais	AE e IF com parâmetros pré-selecionados, avaliação temporal, concordância e associação MEV.

A comparação ao longo do tempo acrescenta outra dimensão. Gama et al. [Gama et al. 2014] discutem a adaptação a *concept drift*, incluindo mudanças na relação entre entradas e alvos. Aqui, acompanhamos mudanças marginais de atributos e escores, mantendo os limiares congelados para observar sua relação com a evolução das sinalizações.

Saito e Rehmsmeier [Saito and Rehmsmeier 2015] discutem ROC e Precision-Recall em populações desbalanceadas. Precision caracteriza a composição do conjunto sinalizado, e recall, a recuperação da referência positiva. Combinamos ROC-AUC, AP e concentração no topo do ranking para distinguir ordenação global, cobertura e volume de investigação.

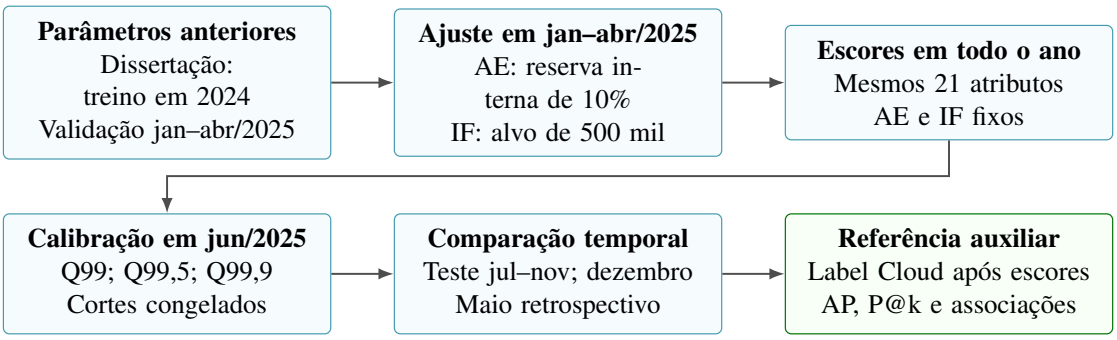
Neste artigo, a unidade é a transação executada e a tarefa é priorizar operações sob um orçamento de investigação. Reconstrução e isolamento são comparados com atributos comuns e limiares congelados. A decomposição em conjuntos exclusivos e compartilhados descreve a concordância ao longo do ano, e a associação histórica por remetente permite avaliar a concentração no topo dos rankings. Essa avaliação fornece uma base para investigar posteriormente os padrões estruturais das operações priorizadas.

3. Metodologia

O protocolo distingue parâmetros pré-selecionados, ajuste dos modelos, calibração e avaliação (Figura 2). AE e IF recebem a mesma representação e pontuam toda a população de cada recorte. A referência histórica é vinculada somente após a inferência.

3.1. Dados e representação transacional

Utilizamos os Parquets diários de transações da Ethereum Mainnet do AWS Public Blockchain Data [Amazon Web Services 2026]. São 523.937.952 registros disponíveis nos 365 dias de 2025, processados em UTC. A população corresponde aos arquivos



O Label Cloud não participa da seleção de hiperparâmetros, do ajuste ou da calibração.

Figura 2. Protocolo experimental. Os cortes definidos em junho permanecem fixos nas demais janelas; o Label Cloud é utilizado exclusivamente na avaliação auxiliar.

da fonte utilizada, sem pressupor reconciliação integral com um índice externo de blocos. A auditoria verifica esquema, chaves, nulos, finitude, limites inteiros e consistência temporal; hashes e contagens identificam as entradas e saídas. O identificador de cada transação é $r = b\,2^{32} + i$, com número do bloco b e índice intrabloco i.

Tabela 2. Recortes de 2025, datas inclusivas em UTC.

Recorte	Período	Transações	Uso
Treino	01/01–30/04	147.512.905	Ajuste
Pectra	01/05–31/05	41.982.829	Retrospectiva
Validação	01/06–30/06	41.950.663	Calibração
Teste	01/07–30/11	241.020.375	Avaliação
Fusaka/BPO1	01/12–09/12	14.264.473	Transição
Estresse	10/12–31/12	37.206.707	Estresse temporal

A Tabela 2 separa ajuste, calibração e avaliação. Maio é retrospectivo, pois utiliza os cortes de junho. Dezembro é dividido em 1–9 e 10–31. Pectra, ativada em 7 de maio, e Fusaka/BPO1, em 3 e 9 de dezembro, são marcos de contextualização [Ethereum Foundation 2025b, Ethereum Foundation 2025a]; as janelas incluem dias anteriores às ativações e descrevem regimes, sem atribuição causal aos forks.

Denominamos B a representação de 21 atributos da Tabela 3; a letra identifica esse conjunto, definido integralmente aqui. Os atributos descrevem execução, valor, taxas, tipos, contexto intrabloco e tempo. Contagens e ranks utilizam todos os registros disponíveis do bloco. A unidade de análise é a transação após inclusão e execução, cujos atributos de recibo e posição já são observáveis.

O preço efetivo usa o valor do recibo, o preço informado na transação como alternativa e zero quando ambos faltam. A razão preço efetivo/taxa máxima vale zero se a taxa máxima estiver ausente ou for não positiva. Para a razão gás usado/limite, o limite ausente ou não positivo também produz zero. Antes de aplicar $\ell(x) = \ln(1 + x)$, valores ausentes ou negativos dos atributos logarítmicos de gás usado, taxas máximas,

Tabela 3. Representação B: os 21 atributos na ordem da matriz. $\ell(x) = \ln(1 + x)$**.**

Posições	Atributos
1–2	ℓ(gás usado); gás usado/limite.
3–6	ℓ(preço efetivo); ℓ(taxa máxima); ℓ(prioridade máxima); preço efetivo/taxa máxima.
7–9	ℓ(valor); ℓ(nonce); status do recibo.
10–12	Indicadores dos tipos 0, 1 e 3, respectivamente.
13–17	Posição relativa; ℓ(número de transações no bloco); ℓ(contagem por remetente); ℓ(contagem por destinatário); rank percentual do preço efetivo.
18–21	Seno e cosseno da hora; seno e cosseno do dia da semana.

prioridade, valor e nonce são tratados como zero. Os tipos 2 e 4 têm os indicadores 0, 1 e 3 em zero. A verificação de finitude abrange as 21 colunas de todas as matrizes, antes e após o pré-processamento.

Os nove atributos logarítmicos recebem a transformação robusta $z_j = (\ell(x_j) - m_j)/\mathrm{IQR}_j$, com mediana e IQR estimados no treino e escala unitária quando o IQR é zero. Os tipos legados 0/1 são excluídos do ajuste da escala dos dois atributos de taxas máximas e mantidos em zero nessas colunas. Indicadores, razões, ranks e componentes cíclicos preservam suas escalas. As matrizes são armazenadas em precisão dupla e convertidas para `float32` na entrada dos modelos.

3.2. Modelos e procedência dos hiperparâmetros

Os parâmetros foram selecionados anteriormente na dissertação, em 5% dos blocos completos: treino de abril a dezembro de 2024 e validação de janeiro a abril de 2025. A grade combinou três arquiteturas, duas taxas de aprendizado e dois valores de weight decay para o AE; para o IF, três quantidades de árvores e quatro tamanhos de amostra por árvore. Foram 12 candidatos por algoritmo, avaliados em cinco representações, totalizando 120 ajustes de busca. O critério foi a maior média das cinco APs na coorte de validação semântica, definida por rótulos de transação e exclusão dos conflitos do protocolo anterior. A seleção anterior empregou esses rótulos semânticos. Neste estudo, AE e IF foram ajustados sem rótulos.

Transferimos o vencedor global de cada algoritmo, preservado em `hiperparametros-dissertacao.json` por SHA-256, e realizamos um novo ajuste na representação B (Tabela 4). A validação anterior de janeiro a abril coincide com o período de treino deste artigo; junho e julho–novembro não entram no critério da busca anterior. A transferência fixa uma configuração comum à comparação, sem nova seleção específica para B pelo Label Cloud ou pelos resultados do teste.

O AE possui arquitetura $21 \to 16 \to 8 \to 4 \to 8 \to 16 \to 21$, LeakyReLU de inclinação 0,1 e saída linear. Emprega AdamW, learning rate 3×10^{-4}, weight decay zero, lotes de 65.536 e precisão mista na GPU. A reserva interna segue $r \bmod 10 = 0$, dentro de janeiro–abril, e os demais registros ajustam os pesos. São transações do mesmo período, não uma separação por remetentes ou blocos independentes. O limite é 200 épocas, com early stopping após 12 épocas sem melhora superior a 10^{-5} na perda interna.

Tabela 4. Hiperparâmetros pré-selecionados e regras de ajuste do artigo.

Modelo	Parâmetro ou regra	Valor
AE	Arquitetura	$21 \to 16 \to 8 \to 4 \to 8 \to 16 \to 21$
AE	Learning rate; weight decay	3×10^{-4}; zero
AE	Otimizador; perda	AdamW; MSE de reconstrução
AE	Batch; limite de épocas	65.536; 200
AE	Patience; melhora mínima	12 épocas; 10^{-5}
IF	Árvores; amostras por árvore	100; até 2.048
IF	Alvo da população de ajuste	500.000 transações
Ambos	Semente; representação	42; B com 21 atributos

O estado aceito por esse critério produz o escore MSE:

$$s_{AE}(x) = \frac{1}{21} \sum_{j=1}^{21} (x_j - \widehat{x}_j)^2. \tag{1}$$

O IF utiliza 100 árvores, até 2.048 exemplos por árvore, todos os atributos, `bootstrap=False` e `contamination=auto`. O conjunto de ajuste segue $h(r) \bmod N < \min(N, 500.000)$, com a função `hash` do DuckDB 1.5.5 e $N = 147.512.905$. O alvo de 500 mil limita o custo do ajuste; a amostragem de cada árvore é uma decisão distinta. Essa configuração algorítmica explica a diferença de população de ajuste em relação ao AE. O escore é o negativo de `score_samples`. Ambos usam semente 42; escores maiores indicam maior anormalidade.

3.3. Calibração e protocolo de avaliação

Estimamos em junho os quantis exatos Q99, Q99,5 e Q99,9, com regra $s_m(x) \geq \tau_{m,q}$ e cortes congelados. Q99,5 é o ponto principal; os demais avaliam sensibilidade à seletividade. Para conjuntos sinalizados A e I, registramos volumes, taxas, união, interseção e exclusivos, com $J(A, I) = |A \cap I|/|A \cup I|$; dois conjuntos vazios recebem valor 1. União e interseção são políticas de conjunto com cardinalidades diferentes, enquanto a comparação dos rankings usa o mesmo k por recorte.

O CSV histórico do Etherscan Label Cloud [Etherscan 2021], com data de captura desconhecida, contém 3.913 linhas e 3.750 endereços únicos. A categoria `mev_bot` é reconstruída a partir das linhas 164 a 3.911, numeradas a partir da primeira linha de dados. Após a normalização para minúsculas, um endereço é positivo se ao menos uma de suas ocorrências pertence à categoria. A regra identifica 3.748 endereços positivos distintos. O CSV é identificado pelo SHA-256 registrado no perfil do experimento.

Na avaliação positiva–não rotulada, uma transação recebe o vínculo histórico quando seu remetente pertence a esse conjunto. As demais transações permanecem sem rótulo de associação. As métricas calculadas em relação a esse vínculo quantificam a recuperação e a concentração de transações associadas no ranking. A verificação de ataques individuais requer evidência semântica.

Em cada recorte, um remetente é ativo se enviou ao menos uma transação associada. Ordenamos esses remetentes por frequência e dividimos a soma das contagens dos 10 ou 100 mais frequentes pelo total de associadas do recorte. Quando há menos de 100 ativos, o top-100 abrange todos.

Seja M o conjunto de associadas. Calculamos $A \cap M$, $I \cap M$, $(A \cap I) \cap M$ e $(A \cup I) \cap M$, com suas parcelas exclusivas. A concentração na interseção divide o número de associadas por $|A \cap I|$; a composição do gráfico divide cada parcela por $|(A \cup I) \cap M|$. Os denominadores respondem a questões distintas.

ROC-AUC e AP utilizam todos os grupos de escores empatados; somente as curvas são reduzidas para apresentação. Precision é a proporção de associadas entre as selecionadas; recall, a fração de associadas recuperada. AP pondera os incrementos de recall pela precision correspondente. Para orçamento f, selecionamos $k = \lceil fN_t \rceil$, com desempate por r, e informamos P@k, contagem de associadas e lift sobre a prevalência p_t [Saito and Rehmsmeier 2015]. A referência aleatória tem precision esperada p_t, não uma realização amostrada. A comparação AE/IF sob k igual é distinta da cobertura obtida por união ou interseção.

Comparamos atributos e escores ao treino por PSI, com decis fixos e piso de probabilidade 10^{-6}, e distância KS aproximada em até 101 quantis do treino. As análises são descritivas de mudanças marginais e de populações com prevalências e durações diferentes. A repetição de remetentes pode correlacionar transações; as métricas transacionais não são estimativas de desempenho por entidade nem testes de significância baseados em observações independentes.

4. Resultados e discussão

4.1. Ajuste e resposta temporal

O AE atingiu MSE interno de 0,10244 na época 200, com 132.718.736 transações para ajuste e 14.794.169 para validação interna. O IF foi ajustado com 500.637 transações. O ajuste levou 2h13min44s no AE e 9,16s no IF. A inferência anual levou 4min32s e 14min19s, respectivamente. Os tempos incluem a verificação das saídas e descrevem execuções distintas em GPU RTX 3060 (AE) e CPU com oito threads (IF).

Os limiares de referência Q99,5 foram $\tau_{AE} = 0{,}42453$ e $\tau_{IF} = 0{,}58162$. A Tabela 5 mostra que cortes congelados produzem volumes diferentes entre períodos. No teste, o AE sinalizou 4.207.945 transações (1,746%) e o IF, 2.557.613 (1,061%). A interseção reuniu 956.106 registros, e a união, 5.809.452, com Jaccard de 0,165. Esse resultado responde à RQ1 e motiva examinar, na RQ2, quais registros cada conjunto acrescenta.

Na transição Fusaka/BPO1, AE e IF sinalizaram 8,943% e 1,335% em Q99,5. No estresse, as taxas foram 8,148% e 1,745%, cerca de 16,3 e 3,5 vezes a calibração nominal. A expansão do AE persiste em Q99 e Q99,9.

Do teste ao estresse, o PSI dos escores aumentou de 0,030 para 0,657 no AE e de 0,090 para 0,941 no IF (Figura 3). O AE ampliou mais a sinalização, pois a decisão depende da cauda acima do corte, enquanto o PSI resume mudanças entre intervalos. O PSI do preço efetivo passou de 0,763 para 2,958, e o da taxa máxima, de 0,452 para 1,606.

Tabela 5. Sinalizações e concordância em Q99,5. Taxas em porcentagem.

Recorte	AE (n)	AE (%)	IF (n)	IF (%)	Jaccard
Treino	1.226.317	0,831	700.520	0,475	0,159
Pectra	298.667	0,711	236.443	0,563	0,197
Validação	209.754	0,500	209.758	0,500	0,124
Teste	4.207.945	1,746	2.557.613	1,061	0,165
Fusaka/BPO1	1.275.618	8,943	190.482	1,335	0,074
Estresse	3.031.586	8,148	649.182	1,745	0,065

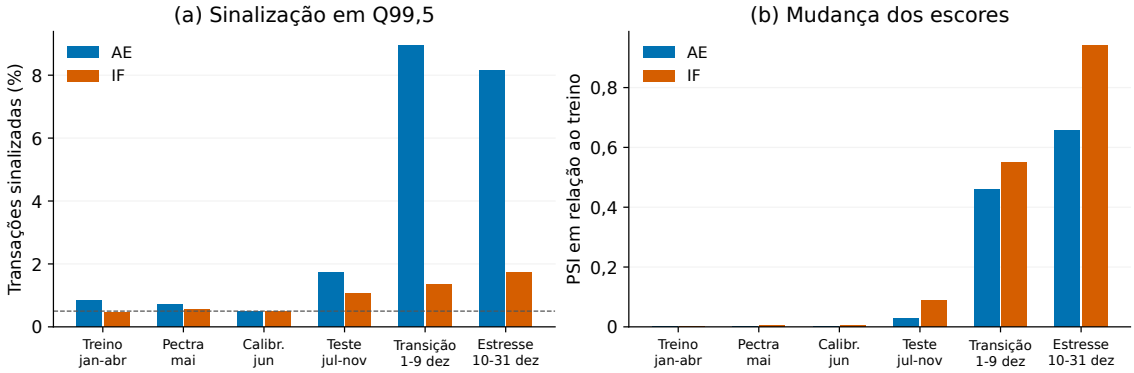


Figura 3. Sinalização em Q99,5 e PSI dos escores em relação ao treino. Junho define os limiares; maio é retrospectivo. Os pontos representam recortes de durações distintas.

4.2. Prioridades de investigação e complementaridade

Tabela 6. Concentração das transações associadas a `mev_bot` por remetente.

Recorte	Ativos	Associadas	Top-10 (%)	Top-100 (%)
Treino	68	1.266.993	99,06	100,00
Pectra	47	431.717	99,00	100,00
Validação	42	534.006	99,66	100,00
Teste	55	4.481.039	99,65	100,00
Fusaka/BPO1	34	144.018	99,46	100,00
Estresse	29	326.074	99,71	100,00

Dos 3.748 endereços de referência, 29 a 68 estiveram ativos em cada recorte (Tabela 6). No teste, 55 remetentes responderam por 4.481.039 transações associadas, das quais 99,65% vieram dos dez mais frequentes. A participação desses dez ficou em torno de 99% ou mais em todos os recortes. Como nenhum recorte alcançou 100 ativos, o top-100 cobre todas as associadas. Essa concentração dá maior peso aos remetentes frequentes nas métricas transacionais e delimita sua interpretação no nível de endereços.

Em Q99,5, a união recuperou 951.073 associadas no teste, ou 21,22% das 4.481.039 (Tabela 7). Ante o IF isolado, acrescentou 193.881 associadas do AE (+25,61%), ampliando o volume de investigação de 2.557.613 para 5.809.452 transações.

No teste, 350.857 das 956.106 sinalizações compartilhadas eram associadas

Tabela 7. Transações associadas a bots MEV sinalizadas em Q99,5.

Recorte	AE	IF	Interseção	União
Treino	6.249	8.097	3.074	11.272
Pectra	9.544	6.420	3.193	12.771
Validação	23.010	23.769	8.920	37.859
Teste	544.738	757.192	350.857	951.073
Fusaka/BPO1	35.508	10.800	5.607	40.701
Estresse	75.354	13.313	5.014	83.653

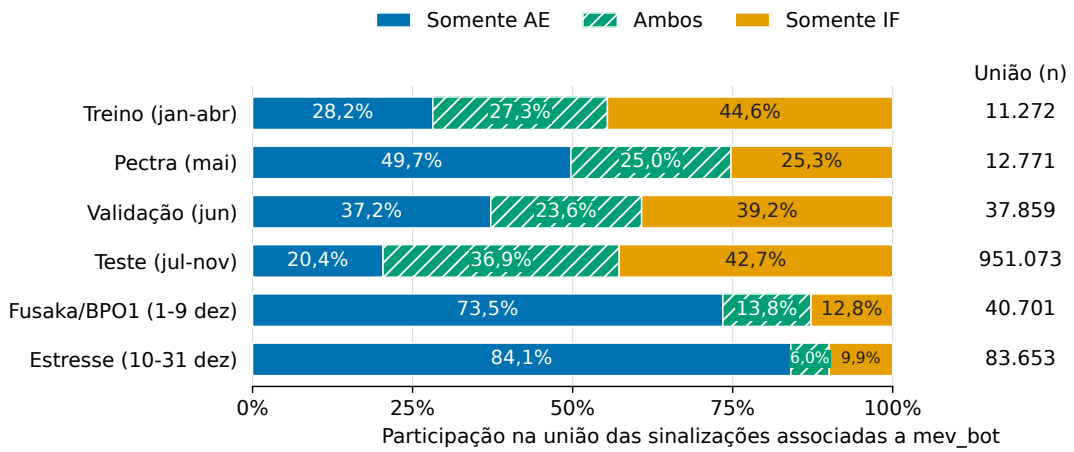


Figura 4. Composição das transações associadas a `mev_bot` sinalizadas em Q99,5. Cada barra corresponde à união associada do recorte; a coluna à direita informa sua quantidade absoluta.

(36,70%), frente a 12,95% no conjunto do AE e 29,61% no do IF. A concentração na interseção foi 19,74 vezes a prevalência de 1,859%. Os volumes das políticas de conjunto diferem.

Entre as 951.073 associadas na união do teste, 20,4% foram exclusivas do AE, 36,9% compartilhadas e 42,7% exclusivas do IF (Figura 4). No estresse, as parcelas foram 84,1%, 6,0% e 9,9%. O IF acrescentou 8.299 associadas ao AE (+11,01%). A interseção concentrou 2,25% de associadas, frente a 2,49% no AE isolado.

Na transição de dezembro, a união reuniu 40.701 associadas (recall de 28,26%). O IF predominou entre as associadas exclusivas no teste e o AE, em dezembro.

A contribuição dos conjuntos deve ser lida em conjunto com a ordenação sob orçamento igual. A Tabela 8 reúne ROC-AUC, AP e precision nos 1% maiores escores. O IF apresentou maior ROC-AUC e AP em todos os recortes. No teste, sua ROC-AUC foi 0,9481, contra 0,7690 do AE, e sua AP, 0,2067, contra 0,0866. Sob o mesmo orçamento de 2.410.204 transações, o IF priorizou 705.170 associadas e o AE, 196.885: precision de 29,26% e 8,17%, respectivamente. Os lifts foram 15,74 e 4,39 em relação à prevalência do período.

No estresse, a AP do IF permaneceu superior (0,0349 frente a 0,0286), assim como a ROC-AUC (0,8822 frente a 0,6309). Entretanto, nos 1% maiores escores, o AE con-

Tabela 8. Ordenação dos escores frente à associação MEV. $P@1\%$ é a precision nos 1% maiores escores; Prev. é a prevalência (%).

		ROC-AUC		AP		$P@1\%$ (%)	
Recorte	Prev.	AE	IF	AE	IF	AE	IF
Treino	0,859	0,6432	0,9129	0,0128	0,0442	0,58	1,22
Pectra	1,028	0,7132	0,9210	0,0277	0,0633	4,29	4,12
Validação	1,273	0,8111	0,9421	0,1076	0,1219	19,87	15,79
Teste	1,859	0,7690	0,9481	0,0866	0,2067	8,17	29,26
Fusaka/BPO1	1,010	0,6189	0,9040	0,0329	0,0524	8,85	5,67
Estresse	0,876	0,6309	0,8822	0,0286	0,0349	7,12	1,71

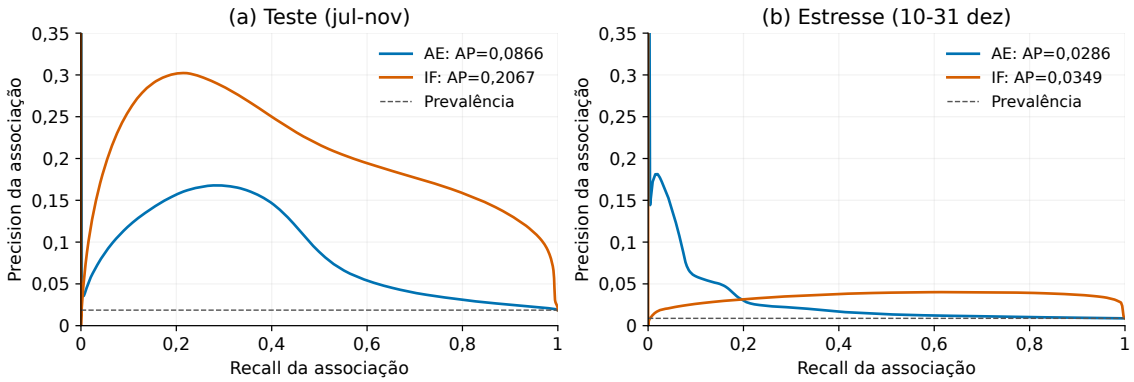


Figura 5. Precision-Recall no teste e no estresse, com eixo vertical de 0 a 0,35. Linhas tracejadas indicam a prevalência, referência aleatória em expectativa. As APs usam todos os grupos de escores, antes da redução de pontos gráficos; ROC-AUC consta na Tabela 8.

centrou 7,12% de associadas, e o IF, 1,71%, para prevalência de 0,876%. O AE priorizou 26.492 associadas nesse orçamento, contra 6.371 do IF. A Figura 5 evidencia que as curvas Precision-Recall podem favorecer métodos diferentes em regiões distintas de recall. A AP resume a ordenação em seu conjunto; a precision sob orçamento fixo descreve uma decisão operacional específica.

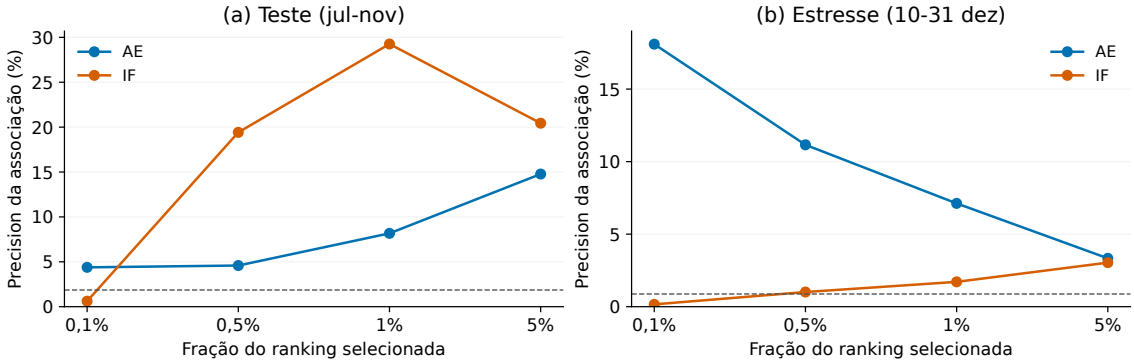


Figura 6. Precision da associação MEV em quatro orçamentos fixos do ranking. Linhas tracejadas indicam a prevalência. O mesmo percentual seleciona a mesma quantidade de transações para ambos os modelos em cada recorte.

No teste, o AE concentrou mais associadas no orçamento de 0,1% (4,38% ante 0,61% do IF, para $k = 241.021$). Nesse ponto, a precision do IF ficou abaixo da prevalência de 1,859%. O IF liderou em 0,5%, 1% e 5%. Na janela de 10 a 31 de dezembro, o AE liderou nos quatro orçamentos: sua precision foi de 18,10% ante 0,16% do IF em 0,1%, e de 3,33% ante 3,04% em 5% (Figura 6). No teste, a precision do AE subiu de 4,38% em 0,1% para 14,77% em 5%. A concentração da associação histórica depende de quanto do ranking se investiga.

Os resultados das RQs indicam que limiares fixos geram volumes distintos, a composição da união varia por recorte e a AP global pode divergir da precision no orçamento de interesse.

5. Conclusões e trabalhos futuros

A comparação de AE e IF em 523.937.952 transações da fonte AWS descreveu a resposta a limiares congelados e a concordância dos detectores em 2025. No teste, em Q99,5, a união recuperou 951.073 associadas e a interseção concentrou 36,70% de associadas em 956.106 sinalizações. As duas políticas oferecem volumes e cobertura distintos.

O IF obteve maior AP em todos os recortes e maior precision em três dos quatro orçamentos do teste. O AE liderou no topo de 0,1% do teste e nos quatro orçamentos da janela de 10 a 31 de dezembro. A concentração de cerca de 99% ou mais das associadas em dez remetentes por recorte motiva avaliar a sensibilidade dos rankings ao volume de cada endereço.

Como continuidade, propomos adaptar os algoritmos de Torres et al. [Torres et al. 2021] para obter candidatos a padrões de inserção, deslocamento e supressão independentemente dos escores. A avaliação semântica combinará ordem transacional, chamadas, recibos, logs, rastros de execução e fluxos de ativos para verificar os papéis dos participantes e os efeitos econômicos. A referência resultante permitirá avaliar como cada política de priorização recupera eventos confirmados.

Disponibilidade de artefatos

O repositório está em `https://github.com/marcelocorni/anomalias-ae-if-2025`. O código e as dependências do experimento estão fixados no commit `852f545`. O perfil `configuracao/execucao_revisao_01.json` aponta para a configuração que registra o SHA-256 do CSV histórico. As entradas externas são os Parquets da AWS e o CSV exato identificado por esse checksum. A documentação de execução descreve a preparação e o comando do perfil.

Os materiais publicados com a revisão anterior incluem `artigo/dados-artigo.json` e `artigo/suplemento/orcamentos.csv`. Esses agregados registram taxas, interseções, PSI e os valores de k, P@k, recall e lift. O suplemento `suplemento/concentracao-remetentes.json` registra a concentração, a assinatura da execução e o hash da referência normalizada. A reprodução das curvas Precision-Recall usa também os pontos dos relatórios de avaliação `labelcloud/`, gerados pelo perfil experimental.

Referências

[Amazon Web Services 2026] Amazon Web Services (2026). AWS Public Blockchain Data. https://registry.opendata.aws/aws-public-blockchain/. Acesso em 17 out. 2026.

[Chaudhary et al. 2026] Chaudhary, U. M. D., Arshad, H., Iqbal, S., Alaulamie, A. A., Raza, M. A., and Iqbal, A. (2026). Explainable anomaly scoring for Ethereum multisignature transactions using temporal validation and LightGBM. *Computers, Materials & Continua*, 89(2). DOI: 10.32604/cmc.2026.084774.

[Daian et al. 2020] Daian, P., Goldfeder, S., Kell, T., Li, Y., Zhao, X., Bentov, I., Breidenbach, L., and Juels, A. (2020). Flash boys 2.0: Frontrunning in decentralized exchanges, miner extractable value, and consensus instability. In *2020 IEEE Symposium on Security and Privacy*, pages 910–927. IEEE. DOI: 10.1109/SP40000.2020.00040.

[Eskandari et al. 2020] Eskandari, S., Moosavi, S., and Clark, J. (2020). SoK: Transparent dishonesty: Front-running attacks on blockchain. In *Financial Cryptography and Data Security*, volume 11599 of *Lecture Notes in Computer Science*, pages 170–189. Springer. DOI: 10.1007/978-3-030-43725-1_13.

[Ethereum Foundation 2025a] Ethereum Foundation (2025a). Fusaka mainnet announcement. https://blog.ethereum.org/2025/11/06/fusaka-mainnet-announcement. Acesso em 17 out. 2026.

[Ethereum Foundation 2025b] Ethereum Foundation (2025b). Pectra mainnet announcement. https://blog.ethereum.org/2025/04/23/pectra-mainnet. Acesso em 17 out. 2026.

[Etherscan 2021] Etherscan (2021). Public name tags, labels & public notes. https://info.etherscan.com/public-name-tags-labels/. Acesso em 17 out. 2026.

[Farrugia et al. 2020] Farrugia, S., Ellul, J., and Azzopardi, G. (2020). Detection of illicit accounts over the Ethereum blockchain. *Expert Systems with Applications*, 150:113318. DOI: 10.1016/j.eswa.2020.113318.

[Gama et al. 2014] Gama, J. a., Žliobaitė, I., Bifet, A., Pechenizkiy, M., and Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4):44:1–44:37. DOI: 10.1145/2523813.

[Heimbach et al. 2023] Heimbach, L., Kiffer, L., Torres, C. F., and Wattenhofer, R. (2023). Ethereum's proposer-builder separation: Promises and realities. In *Proceedings of the 2023 ACM Internet Measurement Conference*, pages 406–420. ACM. DOI: 10.1145/3618257.3624824.

[Li et al. 2024] Li, D., Zhang, K., Wang, L., and Du, G. (2024). A Geth-based real-time detection system for sandwich attacks in Ethereum. *Discover Computing*, 27(1):11. DOI: 10.1007/s10791-024-09445-6.

[Liu et al. 2008] Liu, F. T., Ting, K. M., and Zhou, Z.-H. (2008). Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining*, pages 413–422. IEEE. DOI: 10.1109/ICDM.2008.17.

[Naik et al. 2026] Naik, S. M., Materwala, H., and Svetinovic, D. (2026). MEV detection for Ethereum security: An empirical analysis on agreement and scalability. *IEEE Transactions on Emerging Topics in Computing*, 14(3):1005–1018. DOI: 10.1109/TETC.2026.3700162.

[Podgorelec et al. 2020] Podgorelec, B., Turkanović, M., and Karakatič, S. (2020). A machine learning-based method for automated blockchain transaction signing including personalized anomaly detection. *Sensors*, 20(1):147. DOI: 10.3390/s20010147.

[Saito and Rehmsmeier 2015] Saito, T. and Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3):e0118432. DOI: 10.1371/journal.pone.0118432.

[Sakurada and Yairi 2014] Sakurada, M. and Yairi, T. (2014). Anomaly detection using autoencoders with nonlinear dimensionality reduction. In *Proceedings of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis*, pages 4–11. ACM. DOI: 10.1145/2689746.2689747.

[Torres et al. 2021] Torres, C. F., Camino, R., and State, R. (2021). Frontrunner jones and the raiders of the dark forest: An empirical study of frontrunning on the Ethereum blockchain. In *30th USENIX Security Symposium*, pages 1343–1359. USENIX Association.

[Yao et al. 2025] Yao, Z., Huang, F., Li, Y., Duan, W., Qian, P., Yang, N., and Susilo, W. (2025). Mecon: A GNN-based graph classification framework for MEV activity detection. *Expert Systems with Applications*, 269:126486. DOI: 10.1016/j.eswa.2025.126486.

[Zhang et al. 2024] Zhang, Y., Liu, P., Wang, G., Li, P., Gu, W., Chen, H., Liu, X., and Zhu, J. (2024). FRAD: Front-running attacks detection on Ethereum using ternary classification model. In *Ubiquitous Security*, volume 2034 of *Communications in Computer and Information Science*, pages 63–75. Springer. DOI: 10.1007/978-981-97-1274-8_5.