Detecção de anomalias em transações Ethereum: avaliação temporal de Autoencoder e Isolation Forest

Marcelo Corni Alves[1], **Saulo Moraes Villela**[1],
Heder Soares Bernardino[1], **Alex Borges Vieira**[1]

[1]Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal de Juiz de Fora (UFJF) – Juiz de Fora, MG, Brasil

marcelo.corni@estudante.ufjf.br, saulo.moraes@ufjf.br

heder.bernardino@ufjf.br, alex.borges@ufjf.br

Abstract. *We compare Autoencoder (AE) and Isolation Forest (IF) on 523.9 million Ethereum transactions from 2025 available in the AWS source using 21 on-chain features, previously selected hyperparameters, and thresholds calibrated in June. At Q99.5, during July–November, IF flags 757,192 transactions historically associated with MEV bots, compared with 544,738 for AE. Their intersection concentrates 36.70% associated transactions, while their union recovers 951,073. IF achieves higher Average Precision in every window, but AE concentrates more associated transactions in the top 1% of scores during December. The results distinguish overall ranking quality, temporal response, and investigation budgets, supporting prioritization policies with different investigation volumes.*

Resumo. *Comparamos Autoencoder (AE) e Isolation Forest (IF) em 523,9 milhões de transações Ethereum de 2025, disponíveis na fonte AWS, com 21 atributos on-chain, hiperparâmetros pré-selecionados e limiares calibrados em junho. Em Q99,5, no teste de julho a novembro, o IF sinaliza 757.192 transações historicamente associadas a bots MEV, contra 544.738 do AE. A interseção concentra 36,70% de associadas, e a união recupera 951.073. O IF obtém maior Average Precision em todos os recortes, mas o AE concentra mais associadas no topo de 1% dos escores em dezembro. Os resultados distinguem ordenação global, resposta temporal e orçamento de investigação, caracterizando políticas de priorização com diferentes volumes de investigação.*

1. Introdução

Monitorar a atividade da Ethereum envolve selecionar, entre milhões de operações diárias, transações que merecem investigação após sua execução. Transferências, contratos inteligentes e aplicações financeiras compartilham os mesmos blocos, mas diferem em consumo de gás, taxas, posição e recorrência dos participantes. Esses atributos permitem caracterizar desvios e organizar a triagem em um livro-razão distribuído. A ordenação também possui valor econômico: Daian et al. [Daian et al. 2020] documentam bots de arbitragem e competição por prioridade, e Torres et al. [Torres et al. 2021] investigam padrões de *front-running*. Escores de anomalia podem apoiar a escolha de operações para análise, articulando caracterização da rede e esforço de investigação.

O problema considerado é compreender como dois mecanismos não supervisionados de detecção respondem às mudanças temporais dessa atividade. Aplicar um corte fixo não garante um volume estável de sinalizações; combinar detectores também não informa, por si só, quais transações cada método acrescenta. Além disso, uma boa ordenação global pode coexistir com baixa concentração de operações de interesse nas primeiras posições do ranking. Essas diferenças são relevantes quando a capacidade de inspeção é restrita e a distribuição transacional muda ao longo do tempo.

Comparamos Autoencoder (AE) e Isolation Forest (IF) em 523.937.952 transações disponíveis na fonte AWS nos 365 dias de 2025, descritas pelos mesmos 21 atributos *on-chain*. Os modelos são ajustados de janeiro a abril, com hiperparâmetros escolhidos em estudo anterior, e os limiares são calibrados em junho e mantidos fixos. Investigamos três perguntas: **RQ1**, como o volume sinalizado responde aos diferentes recortes sob cortes congelados? **RQ2**, quanto os modelos concordam e quais são suas contribuições exclusivas? **RQ3**, como a ordenação global se relaciona à concentração de transações associadas a bots MEV sob um mesmo orçamento de análise?

A contribuição é uma caracterização temporal e operacional desses mecanismos na mesma população transacional. Farrugia et al. [Farrugia et al. 2020] classificam contas com atributos agregados, enquanto a literatura de *front-running* identifica relações estruturais entre operações. Aqui, a unidade é a transação executada; a comparação relaciona mudanças marginais, conjuntos compartilhados e exclusivos e decisões sob orçamento fixo. A associação histórica do remetente no Etherscan Label Cloud fornece uma referência auxiliar após a inferência. O estudo quantifica como as prioridades produzidas por reconstrução e isolamento divergem ao longo de 2025, sem tratar essa associação como confirmação de ataques individuais.

A Seção 2 situa essa comparação na literatura. A Seção 3 apresenta os dados e o protocolo; a Seção 4 responde às perguntas por meio das taxas, interseções e rankings. A Seção 5 sintetiza os achados e a continuidade da investigação.

2. Fundamentação e trabalhos relacionados

A literatura é organizada em três eixos: detecção de anomalias; atividade ilícita, *front-running* e MEV na Ethereum; e avaliação sob desbalanceamento e mudanças temporais. A Figura 1 apresenta o fluxo de leitura e síntese, que compara unidades de análise, atributos, rótulos e objetivos dos estudos.

Quanto aos mecanismos de detecção, Sakurada e Yairi [Sakurada and Yairi 2014] investigam autoencoders para detecção de anomalias por redução não linear de dimensionalidade, em dados artificiais e telemetria. O erro de reconstrução mede o afastamento de uma observação da representação aprendida e fundamenta o escore transacional do AE neste estudo.

Liu et al. [Liu et al. 2008] propõem o Isolation Forest, que constrói árvores aleatórias sobre subamostras e associa caminhos médios curtos a observações mais facilmente isoladas. Reconstrução e isolamento produzem escores com escalas distintas; sua aplicação à mesma população permite comparar conjuntos priorizados pelos dois mecanismos.

Na análise da Ethereum, Farrugia et al. [Farrugia et al. 2020] classificam contas Ethereum com XGBoost, utilizando 42 atributos e 4.681 contas, das quais 2.179 rotuladas

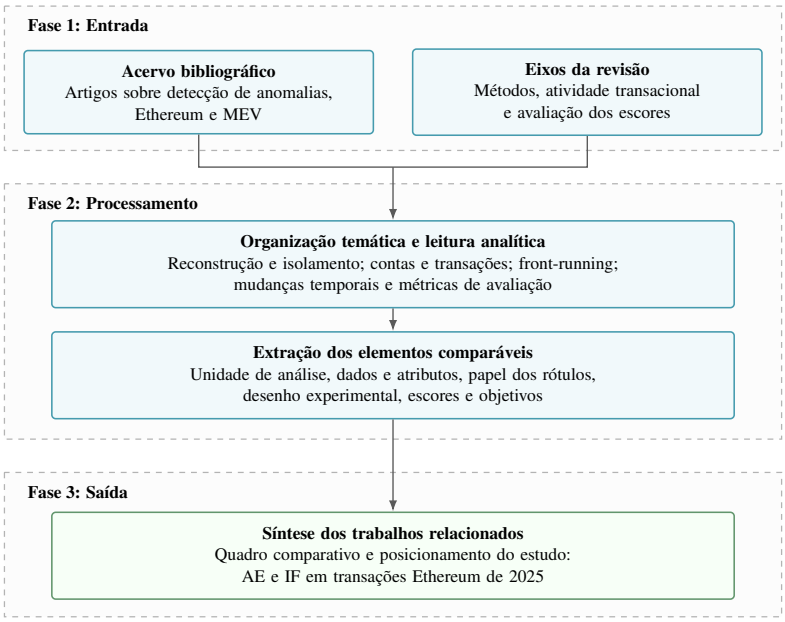


Figura 1. Fluxograma de organização e análise da literatura utilizada nos trabalhos relacionados.

como ilícitas. A agregação do histórico caracteriza a conta; a unidade transacional adotada aqui permite examinar operações individuais de um mesmo remetente.

Podgorelec et al. [Podgorelec et al. 2020] incorporam detecção personalizada de anomalias à assinatura automatizada de transações Ethereum. O perfil individual orienta uma decisão anterior à assinatura, enquanto nosso protocolo examina operações executadas e seu contexto intrabloco.

Daian et al. [Daian et al. 2020] relacionam bots de arbitragem e *priority gas auctions* à extração de valor pela ordenação transacional. Eskandari, Moosavi e Clark [Eskandari et al. 2020] sistematizam *front-running* em deslocamento, inserção e supressão, padrões investigados empiricamente na Ethereum por Torres et al. [Torres et al. 2021]. Esses trabalhos fornecem o contexto econômico e estrutural para interpretar operações priorizadas pelos detectores.

Heimbach et al. [Heimbach et al. 2023] analisam a *proposer-builder separation*, distinguindo construção e proposição dos blocos. Essa organização contextualiza a interpretação conjunta de taxas, posição e contexto transacional na atividade associada a MEV.

Zhang et al. [Zhang et al. 2024] apresentam o FRAD, com classificação ternária de deslocamento, inserção e supressão. Li et al. [Li et al. 2024] integram ao Geth a detecção de ataques *sandwich* em tempo próximo ao real. Enquanto essas abordagens focalizam categorias de ataques, comparamos escores de anomalia em toda a população transacional selecionada (Tabela 1).

A comparação ao longo do tempo acrescenta outra dimensão. Gama et al. [Gama et al. 2014] discutem a adaptação a *concept drift*, incluindo mudanças na relação entre entradas e alvos. Aqui, acompanhamos mudanças marginais de atributos e escores,

Tabela 1. Posicionamento do estudo em relação às abordagens aplicadas à Ethereum.

Trabalho	Unidade ou foco	Abordagem e relação com este estudo
[Farrugia et al. 2020]	Contas ilícitas	Classificação supervisionada por atributos agregados de contas e histórico.
[Podgorelec et al. 2020]	Assinatura de transações	Detecção personalizada associada à decisão de assinatura.
[Torres et al. 2021]	Padrões de front-running	Identificação empírica de inserção, deslocamento e supressão.
[Zhang et al. 2024]	Categorias de front-running	Classificação ternária das categorias de ataque.
[Li et al. 2024]	Ataques sandwich	Detecção integrada ao cliente Geth.
Este artigo	Transações individuais	AE e IF com parâmetros pré-selecionados, avaliação temporal, concordância e associação MEV.

mantendo os limiares congelados para observar sua relação com a evolução das sinalizações.

Saito e Rehmsmeier [Saito and Rehmsmeier 2015] discutem ROC e Precision-Recall em populações desbalanceadas. Precision caracteriza a composição do conjunto sinalizado, e recall, a recuperação da referência positiva. Combinamos ROC-AUC, AP e concentração no topo do ranking para distinguir ordenação global, cobertura e volume de investigação.

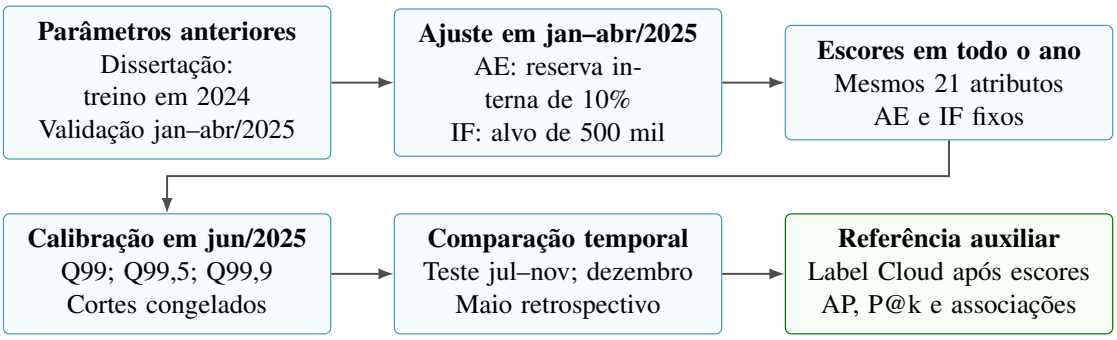
Em síntese, reconstrução e isolamento fundamentam os detectores; os estudos de contas e transações distinguem unidades de análise e supervisão; e a literatura de MEV caracteriza padrões de interesse. Este artigo cruza esses eixos em uma comparação temporal de AE e IF com atributos comuns e parâmetros pré-selecionados. A decomposição da concordância quantifica a contribuição de cada método; ROC, Precision-Recall e associação histórica a bots MEV permitem relacionar essa contribuição às prioridades de investigação. Essa comparação constitui a base para uma futura avaliação semântica dos padrões priorizados.

3. Metodologia

O protocolo distingue parâmetros pré-selecionados, ajuste dos modelos, calibração e avaliação (Figura 2). AE e IF recebem a mesma representação e pontuam toda a população de cada recorte. A referência histórica é vinculada somente após a inferência.

3.1. Dados e representação transacional

Utilizamos os Parquets diários de transações da Ethereum Mainnet do AWS Public Blockchain Data [Amazon Web Services 2026]. São 523.937.952 registros disponíveis nos 365 dias de 2025, processados em UTC. A população corresponde aos arquivos da fonte utilizada, sem pressupor reconciliação integral com um índice externo de blocos. A auditoria verifica esquema, chaves, nulos, finitude, limites inteiros e consistência



O Label Cloud não participa da seleção de hiperparâmetros, do ajuste ou da calibração.

Figura 2. Protocolo experimental. Os cortes definidos em junho permanecem fixos nas demais janelas; o Label Cloud é utilizado exclusivamente na avaliação auxiliar.

temporal; hashes e contagens identificam as entradas e saídas. O identificador de cada transação é $r = b\,2^{32} + i$, com número do bloco b e índice intrabloco i.

Tabela 2. Recortes de 2025, datas inclusivas em UTC.

Recorte	Período	Transações	Uso
Treino	01/01–30/04	147.512.905	Ajuste
Pectra	01/05–31/05	41.982.829	Retrospectiva
Validação	01/06–30/06	41.950.663	Calibração
Teste	01/07–30/11	241.020.375	Avaliação
Fusaka/BPO1	01/12–09/12	14.264.473	Transição
Estresse	10/12–31/12	37.206.707	Estresse temporal

A Tabela 2 separa ajuste, calibração e avaliação. Maio é retrospectivo, pois utiliza os cortes de junho. Dezembro é dividido em 1–9 e 10–31. Pectra, ativada em 7 de maio, e Fusaka/BPO1, em 3 e 9 de dezembro, são marcos de contextualização [Ethereum Foundation 2025b, Ethereum Foundation 2025a]; as janelas incluem dias anteriores às ativações e descrevem regimes, sem atribuição causal aos forks.

Denominamos B a representação de 21 atributos da Tabela 3; a letra identifica esse conjunto, definido integralmente aqui. Os atributos descrevem execução, valor, taxas, tipos, contexto intrabloco e tempo. Contagens e ranks utilizam todos os registros disponíveis do bloco. A unidade de análise é a transação após inclusão e execução, cujos atributos de recibo e posição já são observáveis.

Os nove atributos logarítmicos usam $\ell(x) = \ln(1 + x)$ e transformação robusta $z_j = (\ell(x_j) - m_j)/\mathrm{IQR}_j$, com mediana e IQR estimados apenas no treino; IQR nulo recebe escala unitária. Para taxas máximas e de prioridade, tipos legados 0/1 são excluídos do ajuste da escala e mantidos em zero. Indicadores, razões, ranks e componentes cíclicos preservam suas escalas. As matrizes são armazenadas em precisão dupla e convertidas para `float32` na entrada dos modelos.

Tabela 3. Representação B: os 21 atributos na ordem da matriz. $\ell(x) = \ln(1 + x)$**.**

Posições	Atributos
1–2	ℓ(gás usado); gás usado/limite.
3–6	ℓ(preço efetivo); ℓ(taxa máxima); ℓ(prioridade máxima); preço efetivo/taxa máxima.
7–9	ℓ(valor); ℓ(nonce); status do recibo.
10–12	Indicadores dos tipos 0, 1 e 3, respectivamente.
13–17	Posição relativa; ℓ(número de transações no bloco); ℓ(contagem por remetente); ℓ(contagem por destinatário); rank percentual do preço efetivo.
18–21	Seno e cosseno da hora; seno e cosseno do dia da semana.

3.2. Modelos e procedência dos hiperparâmetros

Os parâmetros foram selecionados anteriormente na dissertação, em 5% dos blocos completos: treino de abril a dezembro de 2024 e validação de janeiro a abril de 2025. A grade combinou três arquiteturas, duas taxas de aprendizado e dois valores de weight decay para o AE; para o IF, três quantidades de árvores e quatro tamanhos de amostra por árvore. Foram 12 candidatos por algoritmo, avaliados em cinco representações, totalizando 120 ajustes de busca. O critério foi a maior média das cinco APs na coorte de validação semântica, definida por rótulos de transação e exclusão dos conflitos do protocolo anterior. Essa referência é distinta do vínculo histórico por remetente usado neste artigo.

Transferimos o vencedor global de cada algoritmo, preservado em `hiperparametros-dissertacao.json` por SHA-256, e realizamos um novo ajuste na representação B (Tabela 4). A validação anterior de janeiro a abril coincide com o período de treino deste artigo; junho e julho–novembro não entram no critério da busca anterior. A transferência fixa uma configuração comum à comparação, sem nova seleção específica para B pelo Label Cloud ou pelos resultados do teste.

Tabela 4. Hiperparâmetros pré-selecionados e regras de ajuste do artigo.

Modelo	Parâmetro ou regra	Valor
AE	Arquitetura	$21 \to 16 \to 8 \to 4 \to 8 \to 16 \to 21$
AE	Learning rate; weight decay	3×10^{-4}; zero
AE	Otimizador; perda	AdamW; MSE de reconstrução
AE	Batch; limite de épocas	65.536; 200
AE	Patience; melhora mínima	12 épocas; 10^{-5}
IF	Árvores; amostras por árvore	100; até 2.048
IF	Alvo da população de ajuste	500.000 transações
Ambos	Semente; representação	42; B com 21 atributos

O AE possui arquitetura $21 \to 16 \to 8 \to 4 \to 8 \to 16 \to 21$, LeakyReLU de inclinação 0,1 e saída linear. Emprega AdamW, learning rate 3×10^{-4}, weight decay zero, lotes de 65.536 e precisão mista na GPU. A reserva interna segue $r \bmod 10 = 0$,

dentro de janeiro–abril, e os demais registros ajustam os pesos. São transações do mesmo período, não uma separação por remetentes ou blocos independentes. O limite é 200 épocas, com early stopping após 12 épocas sem melhora superior a 10^{-5} na perda interna. O estado aceito por esse critério produz o escore MSE:

$$s_{AE}(x) = \frac{1}{21}\sum_{j=1}^{21}(x_j - \widehat{x}_j)^2. \tag{1}$$

O IF utiliza 100 árvores, até 2.048 exemplos por árvore, todos os atributos, `bootstrap=False` e `contamination=auto`. O conjunto de ajuste segue $h(r) \bmod N < \min(N, 500.000)$, com hash do motor de dados e $N = 147.512.905$. O alvo de 500 mil limita o custo do ajuste; a amostragem de cada árvore é uma decisão distinta. Essa configuração algorítmica explica a diferença de população de ajuste em relação ao AE. O escore é o negativo de `score_samples`. Ambos usam semente 42; escores maiores indicam maior anormalidade.

3.3. Calibração e protocolo de avaliação

Estimamos em junho os quantis exatos Q99, Q99,5 e Q99,9, com regra $s_m(x) \geq \tau_{m,q}$ e cortes congelados. Q99,5 é o ponto principal; os demais avaliam sensibilidade à seletividade. Para conjuntos sinalizados A e I, registramos volumes, taxas, união, interseção e exclusivos, com $J(A, I) = |A \cap I|/|A \cup I|$; dois conjuntos vazios recebem valor 1. União e interseção são políticas de conjunto com cardinalidades diferentes, enquanto a comparação dos rankings usa o mesmo k por recorte.

O CSV histórico do Etherscan Label Cloud [Etherscan 2021] contém 3.913 linhas e 3.750 endereços únicos. A data do snapshot não é conhecida; o ano da página bibliográfica não estabelece a data do arquivo. O CSV contém endereços e nomes, com categorias reconstruídas por faixas de posição documentadas no código. Normalizamos os endereços e agrupamos ocorrências antes do vínculo por remetente. A referência positiva indica categoria histórica `mev_bot`; ausência desse vínculo não comprova benignidade. O escore mede anormalidade dos atributos, e as métricas auxiliares medem associação histórica, sem equivalência com ataque confirmado.

Seja M o conjunto de associadas. Calculamos $A \cap M$, $I \cap M$, $(A \cap I) \cap M$ e $(A \cup I) \cap M$, com suas parcelas exclusivas. A concentração na interseção divide o número de associadas por $|A \cap I|$; a composição do gráfico divide cada parcela por $|(A \cup I) \cap M|$. Os denominadores respondem a questões distintas.

ROC-AUC e AP utilizam todos os grupos de escores empatados; somente as curvas são reduzidas para apresentação. Precision é a proporção de associadas entre as selecionadas; recall, a fração de associadas recuperada. AP pondera os incrementos de recall pela precision correspondente. Para orçamento f, selecionamos $k = \lceil fN_t \rceil$, com desempate por r, e informamos P@k, contagem de associadas e lift sobre a prevalência p_t [Saito and Rehmsmeier 2015]. A referência aleatória tem precision esperada p_t, não uma realização amostrada. A comparação AE/IF sob k igual é distinta da cobertura obtida por união ou interseção.

Comparamos atributos e escores ao treino por PSI, com decis fixos e piso de probabilidade 10^{-6}, e distância KS aproximada em até 101 quantis do treino. As análises são

descritivas de mudanças marginais e de populações com prevalências e durações diferentes. A repetição de remetentes pode correlacionar transações; as métricas transacionais não são estimativas de desempenho por entidade nem testes de significância baseados em observações independentes.

4. Resultados e discussão

4.1. Ajuste e resposta temporal

O AE completou 200 épocas, selecionando o estado da última época, com MSE de validação interna de 0,10244. A perda interna caiu de 0,16801 na primeira época para esse valor final, acompanhando a redução da perda de treino de 0,25991 para 0,10239. O ajuste utilizou 132.718.736 transações, com 14.794.169 reservadas para validação interna. O IF foi ajustado em 500.637 transações e produziu escores, assim como o AE, para os 523.937.952 registros do ano. O treinamento do AE levou 2h13min44s e o do IF, 9,16s; a inferência anual consumiu 4min32s e 14min19s, respectivamente, em uma RTX 3060 para o AE e oito threads de CPU para o IF. Os tempos incluem as verificações de saídas e descrevem ambientes distintos de CPU e GPU, sem constituir benchmark de hardware equivalente.

Os limiares de referência Q99,5 foram $\tau_{AE} = 0{,}42453$ e $\tau_{IF} = 0{,}58162$. A Tabela 5 mostra que cortes congelados produzem volumes diferentes entre períodos. No teste, o AE sinalizou 4.207.945 transações (1,746%) e o IF, 2.557.613 (1,061%). A interseção reuniu 956.106 registros, e a união, 5.809.452, com Jaccard de 0,165. Esse resultado responde à RQ1 e motiva examinar, na RQ2, quais registros cada conjunto acrescenta.

Tabela 5. Sinalizações e concordância em Q99,5. Taxas em porcentagem.

Recorte	AE (n)	AE (%)	IF (n)	IF (%)	Jaccard
Treino	1.226.317	0,831	700.520	0,475	0,159
Pectra	298.667	0,711	236.443	0,563	0,197
Validação	209.754	0,500	209.758	0,500	0,124
Teste	4.207.945	1,746	2.557.613	1,061	0,165
Fusaka/BPO1	1.275.618	8,943	190.482	1,335	0,074
Estresse	3.031.586	8,148	649.182	1,745	0,065

Na transição Fusaka/BPO1, a taxa do AE alcançou 8,943%, e a do IF, 1,335%; no estresse, foram 8,148% e 1,745%. Em relação à calibração nominal de 0,5%, o estresse expandiu a sinalização aproximadamente 16,3 vezes no AE e 3,5 vezes no IF. O comportamento também ocorre nos outros cortes: em Q99, as taxas no estresse foram 11,147% e 2,936%; em Q99,9, 3,018% e 0,314%. A expansão do AE, portanto, persiste em diferentes níveis de seletividade.

A Figura 3 relaciona essa resposta às mudanças dos escores. Do teste ao estresse, o PSI passou de 0,030 para 0,657 no AE e de 0,090 para 0,941 no IF. Embora o IF tenha maior PSI dos escores no estresse, o AE apresenta maior expansão da taxa sinalizada. O PSI considera a distribuição nos intervalos de referência, enquanto a decisão depende da massa acima de um corte específico. A leitura conjunta evita equiparar mudança global

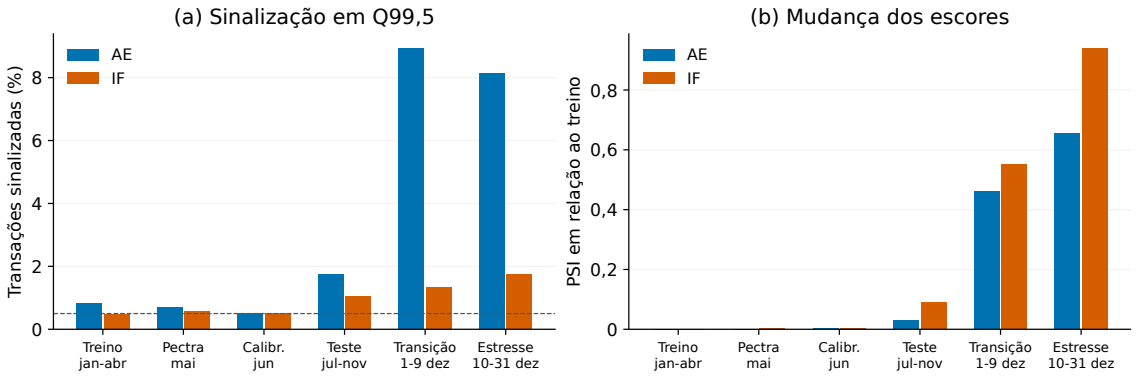


Figura 3. Sinalização em Q99,5 e PSI dos escores em relação ao treino. Junho define os limiares; maio é retrospectivo. Os pontos representam recortes de durações distintas.

de distribuição a crescimento da cauda sinalizada. Nos atributos, o PSI do preço efetivo passou de 0,763 no teste para 2,958 no estresse, e o da taxa máxima, de 0,452 para 1,606, contextualizando a mudança do regime transacional.

4.2. Prioridades de investigação e complementaridade

Tabela 6. Transações associadas a bots MEV sinalizadas em Q99,5.

Recorte	AE	IF	Interseção	União
Treino	6.249	8.097	3.074	11.272
Pectra	9.544	6.420	3.193	12.771
Validação	23.010	23.769	8.920	37.859
Teste	544.738	757.192	350.857	951.073
Fusaka/BPO1	35.508	10.800	5.607	40.701
Estresse	75.354	13.313	5.014	83.653

A Tabela 6 decompõe as transações associadas a `mev_bot` sinalizadas em Q99,5. No teste, o AE recuperou 544.738 associadas, e o IF, 757.192. Os modelos compartilharam 350.857 associadas; 193.881 foram exclusivas do AE e 406.335, do IF. A união alcançou 951.073, correspondentes a 21,22% das 4.481.039 transações associadas do recorte. Em comparação com o IF isolado, a união acrescentou 25,61% de associadas recuperadas, com crescimento do conjunto investigado de 2.557.613 para 5.809.452 registros.

A interseção oferece outra política de priorização: as 350.857 associadas representam 36,70% das 956.106 sinalizações compartilhadas no teste, frente a 12,95% no conjunto do AE e 29,61% no do IF. Sua concentração é aproximadamente 19,74 vezes a prevalência de 1,859% no recorte. No teste, a união aumenta a recuperação, enquanto a interseção reduz o volume e eleva a concentração da referência histórica. Esses conjuntos não foram alinhados a um mesmo orçamento; os ganhos de cobertura são acompanhados pelos volumes correspondentes. Esses números permitem dimensionar o ganho e o custo de combinar os modelos.

A composição varia entre regimes (Figura 4). No teste, 20,4% da união associada são exclusivos do AE, 36,9% compartilhados e 42,7% exclusivos do IF. Esses 36,9%

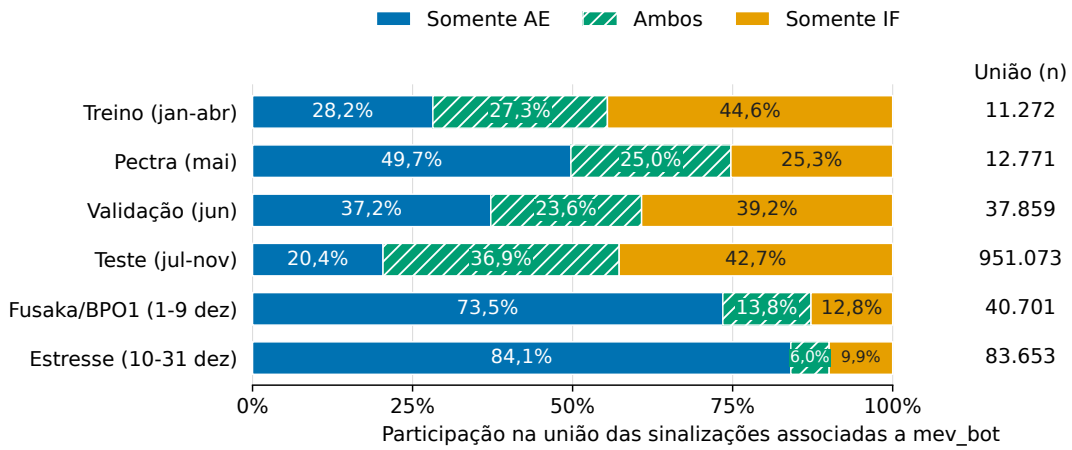


Figura 4. Composição das transações associadas a `mev_bot` sinalizadas em Q99,5. Cada barra corresponde à união associada do recorte; a coluna à direita informa sua quantidade absoluta.

usam como denominador as 951.073 associadas na união, diferentemente dos 36,70% de concentração nas 956.106 sinalizações compartilhadas. No estresse, essas parcelas passam para 84,1%, 6,0% e 9,9%. O AE recuperou 75.354 associadas, contra 13.313 do IF; a união alcançou 83.653, ou 25,65% da referência do período. O IF acrescentou 8.299 associadas ao conjunto do AE, ganho de 11,01%. Nessa janela, a interseção concentrou 2,25% de associadas, abaixo dos 2,49% do AE isolado: concordância entre detectores não assegura maior concentração em todos os regimes.

Na transição de dezembro, o AE recuperou 35.508 associadas e o IF, 10.800, compartilhando 5.607; a união reuniu 40.701, com recall de 28,26%. As três janelas posteriores à calibração mostram, assim, contribuições distintas: o IF predomina entre as associadas exclusivas no teste, enquanto o AE predomina em dezembro. A combinação deve ser interpretada por período e pelo orçamento de investigação, e não como uma regra de superioridade invariável.

A contribuição dos conjuntos deve ser lida em conjunto com a ordenação sob orçamento igual. A Tabela 7 reúne ROC-AUC, AP e precision nos 1% maiores escores.

Tabela 7. Ordenação dos escores frente à associação MEV. $P@1\%$ é a precision nos 1% maiores escores; Prev. é a prevalência (%).

		ROC-AUC		AP		$P@1\%$ (%)	
Recorte	Prev.	AE	IF	AE	IF	AE	IF
Treino	0,859	0,6432	0,9129	0,0128	0,0442	0,58	1,22
Pectra	1,028	0,7132	0,9210	0,0277	0,0633	4,29	4,12
Validação	1,273	0,8111	0,9421	0,1076	0,1219	19,87	15,79
Teste	1,859	0,7690	0,9481	0,0866	0,2067	8,17	29,26
Fusaka/BPO1	1,010	0,6189	0,9040	0,0329	0,0524	8,85	5,67
Estresse	0,876	0,6309	0,8822	0,0286	0,0349	7,12	1,71

O IF apresentou maior ROC-AUC e AP em todos os recortes. No teste, sua ROC-AUC foi 0,9481, contra 0,7690 do AE, e sua AP, 0,2067, contra 0,0866. Sob o mesmo orçamento

de 2.410.204 transações, o IF priorizou 705.170 associadas e o AE, 196.885: precision de 29,26% e 8,17%, respectivamente. Os lifts foram 15,74 e 4,39 em relação à prevalência do período.

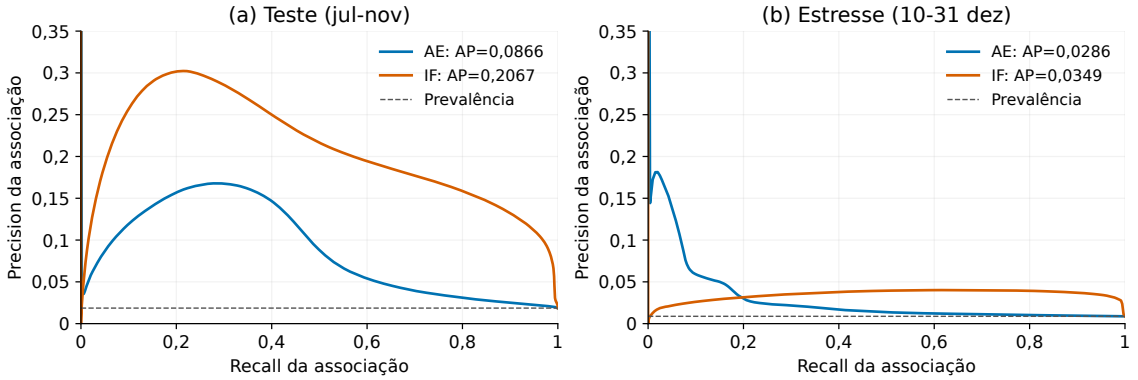


Figura 5. Precision-Recall no teste e no estresse, com eixo vertical de 0 a 0,35. Linhas tracejadas indicam a prevalência, referência aleatória em expectativa. As APs usam todos os grupos de escores, antes da redução de pontos gráficos; ROC-AUC consta na Tabela 7.

No estresse, a AP do IF permaneceu superior (0,0349 frente a 0,0286), assim como a ROC-AUC (0,8822 frente a 0,6309). Entretanto, nos 1% maiores escores, o AE concentrou 7,12% de associadas, e o IF, 1,71%, para prevalência de 0,876%. O AE priorizou 26.492 associadas nesse orçamento, contra 6.371 do IF. A Figura 5 evidencia que as curvas Precision-Recall podem favorecer métodos diferentes em regiões distintas de recall. A AP resume a ordenação em seu conjunto; a precision sob orçamento fixo descreve uma decisão operacional específica.

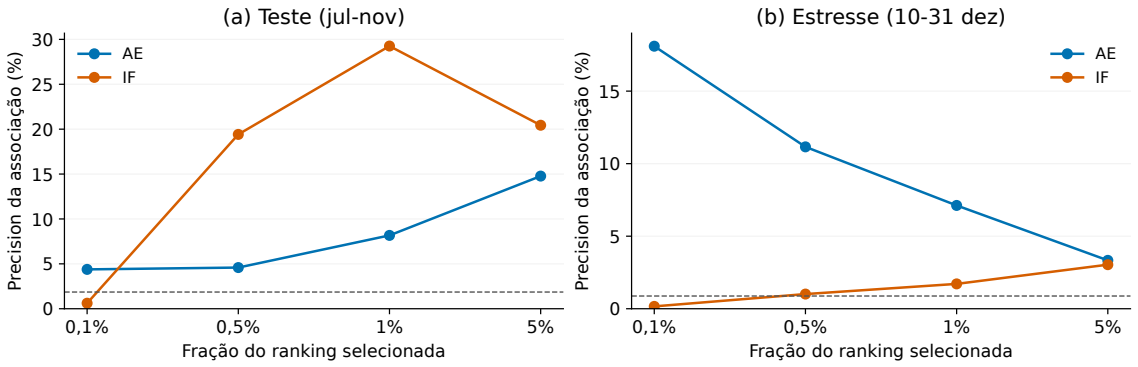


Figura 6. Precision da associação MEV em quatro orçamentos fixos do ranking. Linhas tracejadas indicam a prevalência. O mesmo percentual seleciona a mesma quantidade de transações para ambos os modelos em cada recorte.

A Figura 6 amplia essa comparação. No teste, o IF superou o AE nos quatro orçamentos, de 0,1% a 5%. No estresse, o AE apresentou maior concentração nos quatro: nos 0,1% maiores escores, sua precision foi 18,10%, contra 0,16% do IF, abaixo da prevalência de 0,876%; nos 5%, foram 3,33% e 3,04%. A diferença reduz-se com a ampliação do conjunto investigado. A precision não cresce necessariamente quando o corte se torna mais extremo: no teste, o AE concentra 4,38% no topo de 0,1%, mas 14,77% no topo

de 5%. Logo, escores mais extremos de anormalidade não precisam coincidir com maior concentração dessa categoria histórica.

Em conjunto, a RQ1 evidencia a resposta temporal, a RQ2 decompõe a discordância e a RQ3 distingue ordenação e orçamento: limiares fixos produzem expansão temporal distinta das sinalizações; a sobreposição é parcial e sua composição muda entre recortes; e a qualidade global da ordenação não determina, sozinha, o método mais adequado a um orçamento restrito. A análise de AP, precision, recall e parcelas exclusivas permite escolher entre concentração, recuperação e volume de investigação com critérios quantitativos comuns.

5. Conclusões e trabalhos futuros

A comparação de AE e IF em 523.937.952 transações da fonte Ethereum utilizada caracterizou respostas temporais e conjuntos compartilhados e exclusivos de reconstrução e isolamento. Esses resultados descrevem prioridades de investigação em 2025, sob uma referência histórica por remetente. Com hiperparâmetros pré-selecionados e novos ajustes em 2025, o IF apresentou maior AP em todos os recortes. No teste de julho a novembro, recuperou 757.192 transações associadas a bots MEV em Q99,5, frente às 544.738 do AE, com menor volume sinalizado. A interseção concentrou 36,70% de associadas entre 956.106 sinalizações, enquanto a união ampliou a recuperação para 951.073 associadas.

Em dezembro, o AE passou a contribuir com a maior parcela exclusiva da união associada. No estresse, recuperou 75.354 associadas em Q99,5, contra 13.313 do IF, e concentrou 7,12% no topo de 1%, frente a 1,71%. A AP do IF permaneceu maior nessa janela, distinguindo a ordenação global da concentração obtida sob um orçamento específico. Os achados sustentam a comparação por regime e por objetivo de investigação: interseção, união e ranking individual oferecem compromissos mensuráveis entre concentração, recuperação e esforço de análise.

Como continuidade, propomos adaptar os algoritmos de Torres et al. [Torres et al. 2021] ao contexto da Ethereum de 2025 para identificar candidatos a padrões de inserção, deslocamento e supressão. A geração estrutural será independente dos escores e fornecerá uma referência comum para comparar a cobertura do AE, do IF e de suas sinalizações compartilhadas e exclusivas.

Os candidatos serão submetidos a avaliação semântica, articulando ordem transacional, chamadas de contratos, recibos, logs, rastros de execução e fluxos de ativos. A investigação examinará os papéis dos participantes e os efeitos econômicos, com simulações de cenários alternativos de execução quando pertinentes. Essa extensão permitirá validar padrões concretos de *front-running* e medir como cada política de priorização recupera eventos confirmados. A integração entre escores não supervisionados, detecção estrutural e evidência semântica amplia o uso dos resultados como instrumento de investigação da atividade transacional.

Disponibilidade de artefatos

O código do experimento, commit `852f545`, inclui dependências em `uv.lock`, configurações e instruções. O perfil utilizado é `configuracao/execucao_revisao_01.json`, com os vencedores da dissertação conferidos por SHA-256. Manifestos registram hashes, contagens e tempos; tabelas e métricas agregadas estão em `artigo/dados-artigo.json`. Os Parquets AWS e o CSV histórico são entradas externas. O suplemento `suplemento/orcamentos.csv` do pacote LaTeX apresenta os valores salvos de k, P@k, recall e lift.

Referências

[Amazon Web Services 2026] Amazon Web Services (2026). AWS Public Blockchain Data. `https://registry.opendata.aws/aws-public-blockchain/`. Acesso em 17 out. 2026.

[Daian et al. 2020] Daian, P., Goldfeder, S., Kell, T., Li, Y., Zhao, X., Bentov, I., Breidenbach, L., and Juels, A. (2020). Flash boys 2.0: Frontrunning in decentralized exchanges, miner extractable value, and consensus instability. In *2020 IEEE Symposium on Security and Privacy*, pages 910–927. IEEE. DOI: 10.1109/SP40000.2020.00040.

[Eskandari et al. 2020] Eskandari, S., Moosavi, S., and Clark, J. (2020). SoK: Transparent dishonesty: Front-running attacks on blockchain. In *Financial Cryptography and Data Security*, volume 11599 of *Lecture Notes in Computer Science*, pages 170–189. Springer. DOI: 10.1007/978-3-030-43725-1_13.

[Ethereum Foundation 2025a] Ethereum Foundation (2025a). Fusaka mainnet announcement. `https://blog.ethereum.org/2025/11/06/fusaka-mainnet-announcement`. Acesso em 17 out. 2026.

[Ethereum Foundation 2025b] Ethereum Foundation (2025b). Pectra mainnet announcement. `https://blog.ethereum.org/2025/04/23/pectra-mainnet`. Acesso em 17 out. 2026.

[Etherscan 2021] Etherscan (2021). Public name tags, labels & public notes. `https://info.etherscan.com/public-name-tags-labels/`. Acesso em 17 out. 2026.

[Farrugia et al. 2020] Farrugia, S., Ellul, J., and Azzopardi, G. (2020). Detection of illicit accounts over the Ethereum blockchain. *Expert Systems with Applications*, 150:113318. DOI: 10.1016/j.eswa.2020.113318.

[Gama et al. 2014] Gama, J. a., Žliobaitė, I., Bifet, A., Pechenizkiy, M., and Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4):44:1–44:37. DOI: 10.1145/2523813.

[Heimbach et al. 2023] Heimbach, L., Kiffer, L., Torres, C. F., and Wattenhofer, R. (2023). Ethereum's proposer-builder separation: Promises and realities. In *Proceedings of the 2023 ACM Internet Measurement Conference*, pages 406–420. ACM. DOI: 10.1145/3618257.3624824.

[Li et al. 2024] Li, D., Zhang, K., Wang, L., and Du, G. (2024). A Geth-based real-time detection system for sandwich attacks in Ethereum. *Discover Computing*, 27(1):11. DOI: 10.1007/s10791-024-09445-6.

[Liu et al. 2008] Liu, F. T., Ting, K. M., and Zhou, Z.-H. (2008). Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining*, pages 413–422. IEEE. DOI: 10.1109/ICDM.2008.17.

[Podgorelec et al. 2020] Podgorelec, B., Turkanović, M., and Karakatič, S. (2020). A machine learning-based method for automated blockchain transaction signing including personalized anomaly detection. *Sensors*, 20(1):147. DOI: 10.3390/s20010147.

[Saito and Rehmsmeier 2015] Saito, T. and Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3):e0118432. DOI: 10.1371/journal.pone.0118432.

[Sakurada and Yairi 2014] Sakurada, M. and Yairi, T. (2014). Anomaly detection using autoencoders with nonlinear dimensionality reduction. In *Proceedings of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis*, pages 4–11. ACM. DOI: 10.1145/2689746.2689747.

[Torres et al. 2021] Torres, C. F., Camino, R., and State, R. (2021). Frontrunner jones and the raiders of the dark forest: An empirical study of frontrunning on the Ethereum blockchain. In *30th USENIX Security Symposium*, pages 1343–1359. USENIX Association.

[Zhang et al. 2024] Zhang, Y., Liu, P., Wang, G., Li, P., Gu, W., Chen, H., Liu, X., and Zhu, J. (2024). FRAD: Front-running attacks detection on Ethereum using ternary classification model. In *Ubiquitous Security*, volume 2034 of *Communications in Computer and Information Science*, pages 63–75. Springer. DOI: 10.1007/978-981-97-1274-8_5.