Detecção de anomalias em transações Ethereum: avaliação temporal de Autoencoder e Isolation Forest

Marcelo Corni Alves[1], **Saulo Moraes Villela**[1],
Heder Soares Bernardino[1], **Alex Borges Vieira**[1]

[1]Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal de Juiz de Fora (UFJF) – Juiz de Fora, MG, Brasil

marcelo.corni@estudante.ufjf.br, saulo.moraes@ufjf.br

heder.bernardino@ufjf.br, alex.borges@ufjf.br

Abstract. *We compare Autoencoder (AE) and Isolation Forest (IF) on 523.9 million Ethereum transactions from 2025 using 21 on-chain features, previously selected hyperparameters, and thresholds calibrated in June. At Q99.5, during July–November, IF flags 757,192 transactions historically associated with MEV bots, compared with 544,738 for AE. Their intersection concentrates 36.70% associated transactions, while their union recovers 951,073. IF achieves higher Average Precision in every window, but AE concentrates more associated transactions in the top 1% of scores during December. The results distinguish overall ranking quality, temporal response, and investigation budgets, supporting complementary prioritization policies.*

Resumo. *Comparamos Autoencoder (AE) e Isolation Forest (IF) em 523,9 milhões de transações Ethereum de 2025, com 21 atributos on-chain, hiperparâmetros preselecionados e limiares calibrados em junho. Em Q99,5, no teste de julho a novembro, o IF sinaliza 757.192 transações historicamente associadas a bots MEV, contra 544.738 do AE. A interseção concentra 36,70% de associadas, e a união recupera 951.073. O IF obtém maior Average Precision em todos os recortes, mas o AE concentra mais associadas no topo de 1% dos escores em dezembro. Os resultados distinguem ordenação global, resposta temporal e orçamento de investigação, fundamentando políticas complementares de priorização.*

1. Introdução

A Ethereum reúne transferências de ativos, contratos inteligentes e aplicações financeiras que compartilham o mesmo ambiente de execução. Essa diversidade produz comportamentos transacionais heterogêneos: uma operação pode se destacar pelo consumo de gás, pelas taxas oferecidas, pela posição no bloco ou pela recorrência de seus participantes. Examinar esses desvios em larga escala é relevante para caracterizar a atividade da rede e organizar prioridades de investigação. A competição pela ordenação das transações acrescenta uma dimensão econômica ao problema. Daian et al. [Daian et al. 2020] documentam a atuação de bots de arbitragem e a disputa por prioridade, enquanto Torres et al. [Torres et al. 2021] investigam padrões de *front-running*. Nesse contexto, a detecção de anomalias oferece uma forma de ordenar transações para análise posterior.

O problema considerado neste trabalho é comparar como dois detectores não supervisionados respondem à evolução temporal da atividade transacional. Uma comparação baseada apenas na quantidade de sinalizações não informa se os métodos priorizam os mesmos registros, se recuperam transações associadas a participantes de interesse ou se preservam seu comportamento após mudanças de distribuição. De forma complementar, uma boa ordenação global dos escores pode não corresponder a uma concentração elevada de associados entre as primeiras transações investigadas. Essas questões motivam a análise conjunta dos escores, dos limiares de decisão e das sinalizações compartilhadas e exclusivas, mantendo a separação cronológica entre ajuste, calibração e avaliação.

Neste artigo, comparamos Autoencoder (AE) e Isolation Forest (IF) em 523.937.952 transações disponíveis nos 365 dias de 2025, representadas pelos mesmos 21 atributos *on-chain*. Os hiperparâmetros são fixados a partir de seleção anterior; os modelos são ajustados no primeiro quadrimestre, e os limiares são calibrados em junho e congelados para a avaliação. O desenho permite investigar três questões: como varia o volume sinalizado ao longo do ano; quanto os conjuntos produzidos pelos modelos se sobrepõem; e como os escores priorizam transações de remetentes historicamente associados a bots MEV. As contribuições são a comparação temporal em uma população anual integral da fonte utilizada, a decomposição da concordância em interseção e parcelas exclusivas e a avaliação da relação entre recuperação e concentração da associação MEV em diferentes pontos de operação.

O estudo articula problemas examinados separadamente em trabalhos anteriores. A classificação de contas ilícitas de Farrugia et al. [Farrugia et al. 2020] utiliza atributos agregados e rótulos de contas; aqui, a unidade de análise é a transação individual, descrita também pelo contexto de seu bloco. A literatura de *front-running* identifica estruturas e relações entre operações, enquanto nossa comparação examina a ordenação produzida por reconstrução e isolamento antes de uma futura validação desses padrões. A referência do Etherscan Label Cloud é aplicada após a inferência, permitindo confrontar sinalizações e associação histórica sem utilizá-la no treinamento ou na escolha dos hiperparâmetros deste experimento. Ao manter os cortes congelados, o desenho também torna observável a resposta dos métodos aos diferentes regimes transacionais de 2025.

A Seção 2 organiza os trabalhos relacionados e posiciona a comparação proposta. A Seção 3 descreve os dados, os recortes temporais, a representação, os parâmetros preselecionados e o protocolo de avaliação. A análise dos resultados é organizada pelas taxas de sinalização, pela concordância entre os modelos e pela associação MEV, fornecendo a base para discutir prioridades de investigação e extensões do estudo.

2. Fundamentação e trabalhos relacionados

A literatura é organizada em três eixos: detecção de anomalias; atividade ilícita, *front-running* e MEV na Ethereum; e avaliação sob desbalanceamento e mudanças temporais. A Figura 1 apresenta o fluxo de leitura e síntese, que compara unidades de análise, atributos, rótulos e objetivos dos estudos.

2.1. Reconstrução e isolamento na detecção de anomalias

Sakurada e Yairi [Sakurada and Yairi 2014] investigam autoencoders para detecção de anomalias por redução não linear de dimensionalidade, em dados artificiais e tele-

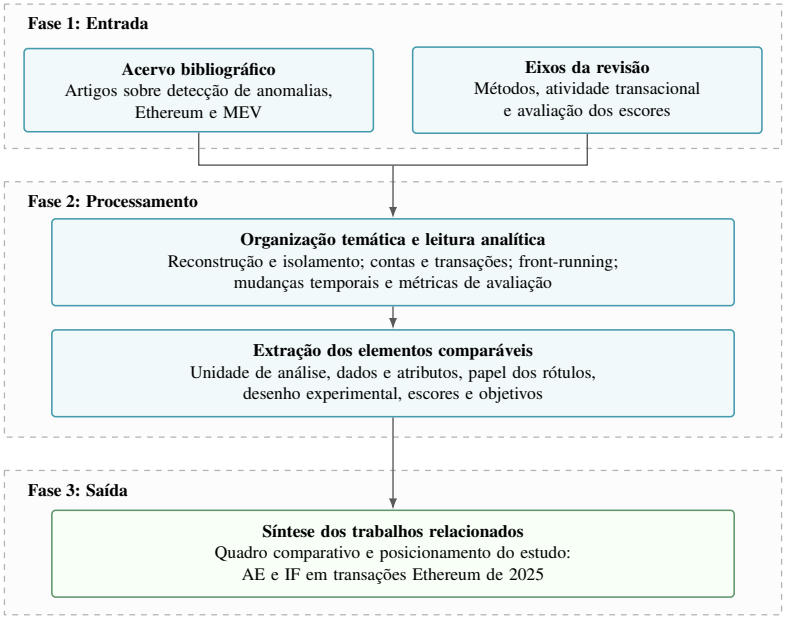


Figura 1. Fluxograma de organização e análise da literatura utilizada nos trabalhos relacionados.

metria. O erro de reconstrução mede o afastamento de uma observação da representação aprendida e fundamenta o escore transacional do AE neste estudo.

Liu et al. [Liu et al. 2008] propõem o Isolation Forest, que constrói árvores aleatórias sobre subamostras e associa caminhos médios curtos a observações mais facilmente isoladas. Reconstrução e isolamento produzem escores com escalas distintas; sua aplicação à mesma população permite comparar conjuntos priorizados pelos dois mecanismos.

2.2. Contas, transações e padrões de MEV na Ethereum

Farrugia et al. [Farrugia et al. 2020] classificam contas Ethereum com XGBoost, utilizando 42 atributos e 4.681 contas, das quais 2.179 rotuladas como ilícitas. A agregação do histórico caracteriza a conta; a unidade transacional adotada aqui permite examinar operações individuais de um mesmo remetente.

Podgorelec et al. [Podgorelec et al. 2020] incorporam detecção personalizada de anomalias à assinatura automatizada de transações Ethereum. O perfil individual orienta uma decisão anterior à assinatura, enquanto nosso protocolo examina operações executadas e seu contexto intrabloco.

Daian et al. [Daian et al. 2020] relacionam bots de arbitragem e *priority gas auctions* à extração de valor pela ordenação transacional. Eskandari, Moosavi e Clark [Eskandari et al. 2020] sistematizam *front-running* em deslocamento, inserção e supressão, padrões investigados empiricamente na Ethereum por Torres et al. [Torres et al. 2021]. Esses trabalhos fornecem o contexto econômico e estrutural para interpretar operações priorizadas pelos detectores.

Heimbach et al. [Heimbach et al. 2023] analisam a *proposer-builder separation*, distinguindo construção e proposição dos blocos. Essa organização contextualiza a interpretação conjunta de taxas, posição e contexto transacional na atividade associada a

MEV.

Zhang et al. [Zhang et al. 2024] apresentam o FRAD, com classificação ternária de deslocamento, inserção e supressão. Li et al. [Li et al. 2024] integram ao Geth a detecção de ataques *sandwich* em tempo próximo ao real. Enquanto essas abordagens focalizam categorias de ataques, comparamos escores de anomalia em toda a população transacional selecionada (Tabela 1).

Tabela 1. Posicionamento do estudo em relação às abordagens aplicadas à Ethereum.

Trabalho	Unidade ou foco	Abordagem e relação com este estudo
[Farrugia et al. 2020]	Contas ilícitas	Classificação supervisionada por atributos agregados de contas e histórico.
[Podgorelec et al. 2020]	Assinatura de transações	Detecção personalizada associada à decisão de assinatura.
[Torres et al. 2021]	Padrões de front-running	Identificação empírica de inserção, deslocamento e supressão.
[Zhang et al. 2024]	Categorias de front-running	Classificação ternária das categorias de ataque.
[Li et al. 2024]	Ataques sandwich	Detecção integrada ao cliente Geth.
Este artigo	Transações individuais	AE e IF com parâmetros preselecionados, avaliação temporal, concordância e associação MEV.

2.3. Avaliação de escores e mudanças temporais

Gama et al. [Gama et al. 2014] discutem a adaptação a *concept drift*, incluindo mudanças na relação entre entradas e alvos. Aqui, acompanhamos mudanças marginais de atributos e escores, mantendo os limiares congelados para observar sua relação com a evolução das sinalizações.

Saito e Rehmsmeier [Saito and Rehmsmeier 2015] discutem ROC e Precision-Recall em populações desbalanceadas. Precision caracteriza a composição do conjunto sinalizado, e recall, a recuperação da referência positiva. Combinamos ROC-AUC, AP e concentração no topo do ranking para distinguir ordenação global, cobertura e volume de investigação.

Em síntese, reconstrução e isolamento fundamentam os detectores; os estudos de contas e transações distinguem unidades de análise e supervisão; e a literatura de MEV caracteriza padrões de interesse. Este artigo cruza esses eixos em uma comparação temporal de AE e IF com atributos comuns e parâmetros preselecionados. A decomposição da concordância quantifica a contribuição de cada método; ROC, Precision-Recall e associação histórica a bots MEV permitem relacionar essa contribuição às prioridades de investigação. Essa comparação constitui a base para uma futura avaliação semântica dos padrões priorizados.

3. Metodologia

O protocolo separa a fixação dos hiperparâmetros, o ajuste no treino, a calibração em junho e a avaliação nos demais recortes. AE e IF utilizam a mesma representação e pontuam toda a população de cada janela.

3.1. Dados e recortes temporais

Utilizamos os Parquets diários de transações da Ethereum Mainnet disponibilizados pelo AWS Public Blockchain Data [Amazon Web Services 2026]. Os 365 dias de 2025 totalizam 523.937.952 registros na fonte utilizada. O processamento interpreta os timestamps em UTC e inclui todas as transações disponíveis de cada dia, preservando o contexto intrabloco usado na construção dos atributos.

Tabela 2. Recortes de 2025, datas inclusivas em UTC.

Recorte	Período	Transações	Uso
Treino	01/01–30/04	147.512.905	Ajuste
Pectra	01/05–31/05	41.982.829	Retrospectiva
Validação	01/06–30/06	41.950.663	Calibração
Teste	01/07–30/11	241.020.375	Avaliação
Fusaka/BPO1	01/12–09/12	14.264.473	Transição
Estresse	10/12–31/12	37.206.707	Estresse temporal

A Tabela 2 distingue o período de ajuste, janeiro a abril, da calibração em junho e do teste de julho a novembro. Maio é analisado retrospectivamente com os cortes calibrados em junho. Dezembro é dividido em uma janela de transição, de 1 a 9, e uma janela de estresse, de 10 a 31. Os marcos Pectra, ativado em 7 de maio, e Fusaka/BPO1, em 3 e 9 de dezembro, contextualizam a organização temporal [Ethereum Foundation 2025b, Ethereum Foundation 2025a]. As comparações caracterizam os regimes observados, sem atribuir a uma atualização isolada as mudanças encontradas.

Cada registro recebe um identificador determinístico $r = b\,2^{32} + i$, em que b é o número do bloco e i é o índice intrabloco. A auditoria verifica limites inteiros, consistência temporal, esquema, chaves, nulos e finitude dos valores. Os manifestos vinculam os arquivos às suas contagens e hashes, permitindo conferir a população processada em cada etapa.

3.2. Representação e pré-processamento

Cada transação é representada pelos 21 atributos da configuração B, agrupados na Tabela 3. Os atributos combinam execução e valor, condições de taxa, tipos de transação, contexto do bloco e componentes cíclicos do tempo. Contagens e ranks intrabloco são construídos com todos os registros disponíveis do bloco. Trata-se de uma representação posterior à inclusão e execução da transação.

Os nove atributos logarítmicos utilizam $\ell(x) = \ln(1 + x)$ e são normalizados por $z_j(x) = (\ell(x_j) - m_j)/\mathrm{IQR}_j$, em que m_j e IQR_j são a mediana e o intervalo interquartil estimados exclusivamente no treino. Um IQR nulo recebe escala unitária. Para taxa máxima e prioridade máxima, tipos legados 0/1 são excluídos do ajuste da escala e mantidos

Tabela 3. Atributos utilizados pelos modelos. $\ell(x) = \ln(1 + x)$**.**

Grupo	Atributos
Execução e valor	ℓ(gás usado); gás usado/limite; ℓ(valor); ℓ(nonce); status do recibo.
Taxas	ℓ(preço efetivo); ℓ(taxa máxima); ℓ(prioridade máxima); preço efetivo/taxa máxima.
Tipos	Indicadores dos tipos 0, 1 e 3.
Contexto do bloco	Posição relativa; ℓ(número de transações); ℓ(contagens por remetente e destinatário); rank percentual do preço efetivo.
Tempo	Seno/cosseno da hora e do dia da semana.

em zero na transformação. Indicadores, razões, ranks e componentes cíclicos preservam suas escalas. Os tipos 0, 1 e 3 possuem indicadores explícitos; tipos 2 e 4 são representados pelos demais atributos. As matrizes são armazenadas em precisão dupla e convertidas para `float32` na entrada dos modelos.

3.3. Origem e fixação dos hiperparâmetros

Os hiperparâmetros são preselecionados em um experimento anterior da dissertação e mantidos fixos neste estudo. Naquele experimento, a grade do AE combinou três arquiteturas simétricas, duas taxas de aprendizado e dois valores de *weight decay*; a grade do IF combinou três quantidades de árvores e quatro tamanhos de amostra por árvore. Cada algoritmo teve 12 candidatos, ajustados em cinco representações transacionais, totalizando 120 ajustes de busca. A escolha foi realizada por algoritmo, pela maior média de AP na validação semântica das cinco representações, com desempate determinístico.

Transferimos os vencedores globais dessa seleção (Tabela 4) para um novo ajuste de um AE e um IF na configuração B de 2025. A escolha precede este experimento. O Label Cloud é aplicado exclusivamente à avaliação posterior, preservando sua independência em relação aos parâmetros, ao treinamento e aos limiares.

Tabela 4. Hiperparâmetros preselecionados e regras de ajuste do artigo.

Modelo	Parâmetro ou regra	Valor
AE	Arquitetura	$21 \to 16 \to 8 \to 4 \to 8 \to 16 \to 21$
AE	Learning rate; weight decay	3×10^{-4}; zero
AE	Otimizador; perda	AdamW; MSE de reconstrução
AE	Batch; limite de épocas	65.536; 200
AE	Patience; melhora mínima	12 épocas; 10^{-5}
IF	Árvores; amostras por árvore	100; até 2.048
IF	Alvo da população de ajuste	500.000 transações
Ambos	Semente; representação	42; B com 21 atributos

3.4. Ajuste dos modelos e produção dos escores

O AE possui arquitetura $21 \to 16 \to 8 \to 4 \to 8 \to 16 \to 21$, LeakyReLU com inclinação 0,1 nas camadas intermediárias e saída linear. O ajuste emprega AdamW,

learning rate 3×10^{-4}, weight decay zero, lotes de 65.536 e precisão mista na GPU. A reserva interna utiliza $r \bmod 10 = 0$ e permanece dentro do intervalo de treino; os demais registros participam do ajuste dos pesos. O limite é de 200 épocas, com *early stopping* após 12 épocas sem melhora aceita superior a 10^{-5} na perda interna. O estado aceito por esse critério é utilizado na inferência.

O escore do AE é o erro quadrático médio de reconstrução dos 21 atributos:

$$s_{AE}(x) = \frac{1}{21} \sum_{j=1}^{21} \left(x_j - \widehat{x}_j\right)^2. \tag{1}$$

O processamento por lotes utiliza matrizes mapeadas em disco; checkpoints preservam o modelo, o otimizador e os estados necessários à retomada.

O IF utiliza 100 árvores, até 2.048 exemplos por árvore, todos os atributos, `bootstrap=False` e `contamination=auto`. Seu conjunto de ajuste é obtido pela regra determinística $h(r) \bmod N < \min(N, 500.000)$, em que N é a quantidade de transações do treino e h é a função de hash utilizada pelo motor de dados. A quantidade efetivamente selecionada é registrada no manifesto e pode diferir do alvo. Essa seleção define a população disponível para ajuste; as 2.048 amostras por árvore são uma decisão distinta. O escore é o negativo de `score_samples`. Ambos os algoritmos usam semente 42 e pontuam todos os registros das janelas, com escores maiores indicando maior anormalidade.

3.5. Calibração e concordância das sinalizações

Para cada algoritmo m, os cortes $\tau_{m,q}$ são os quantis exatos Q99, Q99,5 e Q99,9 de seus escores na validação de junho. A regra de sinalização é $s_m(x) \geq \tau_{m,q}$. Os cortes permanecem congelados nas demais janelas, preservando também os empates no limiar. Q99,5 é o ponto de operação principal; os demais cortes permitem examinar a sensibilidade ao volume de investigação.

Para um recorte t e um quantil q, sejam $A_{t,q}$ e $I_{t,q}$ os conjuntos sinalizados por AE e IF. Registramos suas taxas, interseção, união e parcelas exclusivas. A concordância é $J(A_{t,q}, I_{t,q}) = |A_{t,q} \cap I_{t,q}|/|A_{t,q} \cup I_{t,q}|$, com valor 1 para dois conjuntos vazios. A interseção prioriza concordância; a união permite investigar qualquer sinalização.

3.6. Referência auxiliar e avaliação da ordenação

O CSV histórico do Etherscan Label Cloud [Etherscan 2021] contém 3.913 linhas e 3.750 endereços únicos. Os endereços são normalizados para minúsculas e suas ocorrências agrupadas antes do vínculo pelo remetente. Uma transação é associada quando seu remetente possui a categoria `mev_bot`; as demais são denominadas não associadas. A referência caracteriza uma associação histórica de endereços, não a confirmação de um ataque individual. Sua identificação por SHA-256 fixa o arquivo utilizado.

Seja M_t o conjunto de associadas. Calculamos $A_{t,q} \cap M_t$, $I_{t,q} \cap M_t$, a interseção $(A_{t,q} \cap I_{t,q}) \cap M_t$ e a união $(A_{t,q} \cup I_{t,q}) \cap M_t$, além das parcelas exclusivas. O gráfico de composição normaliza a união associada para 100% e informa seu tamanho absoluto.

ROC-AUC e AP são calculadas a partir de todos os grupos de escores empatados. A redução de pontos é restrita à apresentação gráfica das curvas ROC e Precision-Recall.

Para cada limiar, a *precision* auxiliar é a proporção de associados entre os sinalizados, e o *recall* é a fração de associados recuperada. A AP integra os incrementos de recall ponderados pela precision correspondente. Também são registrados a área PR trapezoidal e os resultados sob orçamentos fixos no topo do ranking. O conjunto dos 1% maiores escores utiliza $k = \lceil 0{,}01 N_t \rceil$, com desempate por r; seu *lift* compara a concentração de associados à prevalência no recorte. Essas medidas distinguem a qualidade da ordenação e a composição dos conjuntos priorizados [Saito and Rehmsmeier 2015].

3.7. Caracterização das mudanças de distribuição

Comparamos atributos e escores ao treino por PSI, com intervalos definidos pelos decis do treino e piso de probabilidade 10^{-6}, e distância de Kolmogorov–Smirnov aproximada. Esta última avalia a maior diferença absoluta entre as distribuições acumuladas em até 101 quantis do treino. As fronteiras permanecem fixas, caracterizando mudanças marginais entre recortes.

3.8. Reprodutibilidade

O código está disponível no repositório público no GitHub, com instruções de execução. O arquivo `uv.lock` fixa as dependências, e as configurações registram atributos, recortes, semente e hiperparâmetros. Os vencedores da seleção anterior e o CSV do Label Cloud são identificados por SHA-256. O perfil da revisão integra processamento, avaliações, interseções e figuras; manifestos registram hashes, contagens e tempos por etapa, permitindo retomadas conferidas. Os Parquets da AWS e o CSV histórico são entradas externas, com preparação descrita na documentação.

4. Resultados e discussão

4.1. Ajuste e resposta temporal das sinalizações

O AE completou 200 épocas, selecionando o estado da última época, com MSE de validação interna de 0,10244. A perda interna caiu de 0,16801 na primeira época para esse valor final, acompanhando a redução da perda de treino de 0,25991 para 0,10239. O ajuste utilizou 132.718.736 transações, com 14.794.169 reservadas para validação interna. O IF foi ajustado em 500.637 transações e produziu escores, assim como o AE, para os 523.937.952 registros do ano. O treinamento do AE levou 2h13min44s e o do IF, 9,16s; a inferência anual consumiu 4min32s e 14min19s, respectivamente, em uma RTX 3060 para o AE e oito threads de CPU para o IF. Os tempos das etapas incluem as verificações de suas saídas.

Os limiares de referência Q99,5 foram $\tau_{AE} = 0{,}42453$ e $\tau_{IF} = 0{,}58162$. A Tabela 5 mostra que cortes congelados produzem volumes diferentes entre períodos. No teste, o AE sinalizou 4.207.945 transações (1,746%) e o IF, 2.557.613 (1,061%). A interseção reuniu 956.106 registros, e a união, 5.809.452, com Jaccard de 0,165. Assim, os métodos compartilham uma parcela dos registros, mas cada um acrescenta um conjunto expressivo à investigação.

Na transição Fusaka/BPO1, a taxa do AE alcançou 8,943%, e a do IF, 1,335%; no estresse, foram 8,148% e 1,745%. Em relação à calibração nominal de 0,5%, o estresse expandiu a sinalização aproximadamente 16,3 vezes no AE e 3,5 vezes no IF. O comportamento também ocorre nos outros cortes: em Q99, as taxas no estresse foram

Tabela 5. Sinalizações e concordância em Q99,5. Taxas em porcentagem.

Recorte	AE (n)	AE (%)	IF (n)	IF (%)	Jaccard
Treino	1.226.317	0,831	700.520	0,475	0,159
Pectra	298.667	0,711	236.443	0,563	0,197
Validação	209.754	0,500	209.758	0,500	0,124
Teste	4.207.945	1,746	2.557.613	1,061	0,165
Fusaka/BPO1	1.275.618	8,943	190.482	1,335	0,074
Estresse	3.031.586	8,148	649.182	1,745	0,065

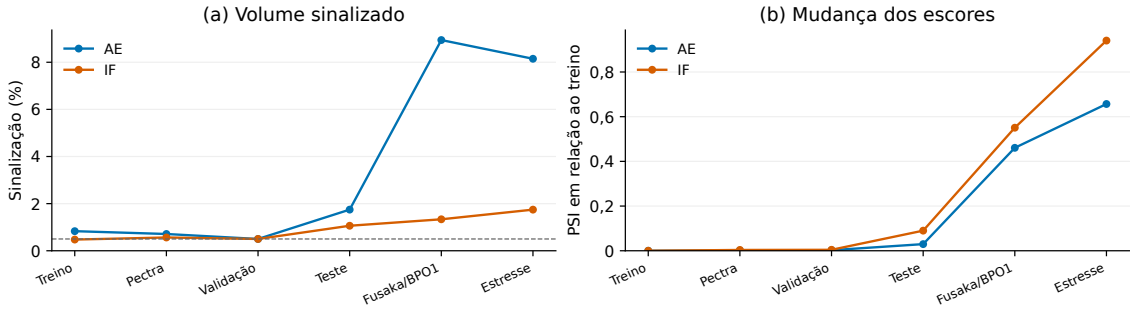


Figura 2. Sinalização em Q99,5 e PSI dos escores em relação ao treino. Junho define os limiares; maio é retrospectivo. Os pontos representam recortes de durações distintas.

11,147% e 2,936%; em Q99,9, 3,018% e 0,314%. A expansão do AE, portanto, persiste em diferentes níveis de seletividade.

A Figura 2 relaciona essa resposta às mudanças dos escores. Do teste ao estresse, o PSI passou de 0,030 para 0,657 no AE e de 0,090 para 0,941 no IF. Embora o IF tenha maior PSI dos escores no estresse, o AE apresenta maior expansão da taxa sinalizada. O PSI considera a distribuição nos intervalos de referência, enquanto a decisão depende da massa acima de um corte específico. A leitura conjunta evita equiparar mudança global de distribuição a crescimento da cauda sinalizada. Nos atributos, o PSI do preço efetivo passou de 0,763 no teste para 2,958 no estresse, e o da taxa máxima, de 0,452 para 1,606, contextualizando a mudança do regime transacional.

4.2. Interseções e contribuição exclusiva dos modelos

Tabela 6. Transações associadas a bots MEV sinalizadas em Q99,5.

Recorte	AE	IF	Interseção	União
Treino	6.249	8.097	3.074	11.272
Pectra	9.544	6.420	3.193	12.771
Validação	23.010	23.769	8.920	37.859
Teste	544.738	757.192	350.857	951.073
Fusaka/BPO1	35.508	10.800	5.607	40.701
Estresse	75.354	13.313	5.014	83.653

A Tabela 6 decompõe as transações associadas a `mev_bot` sinalizadas em Q99,5.

No teste, o AE recuperou 544.738 associadas, e o IF, 757.192. Os modelos compartilharam 350.857 associadas; 193.881 foram exclusivas do AE e 406.335, do IF. A união alcançou 951.073, correspondentes a 21,22% das 4.481.039 transações associadas do recorte. Em comparação com o IF isolado, a união acrescentou 25,61% de associadas recuperadas, com crescimento do conjunto investigado de 2.557.613 para 5.809.452 registros.

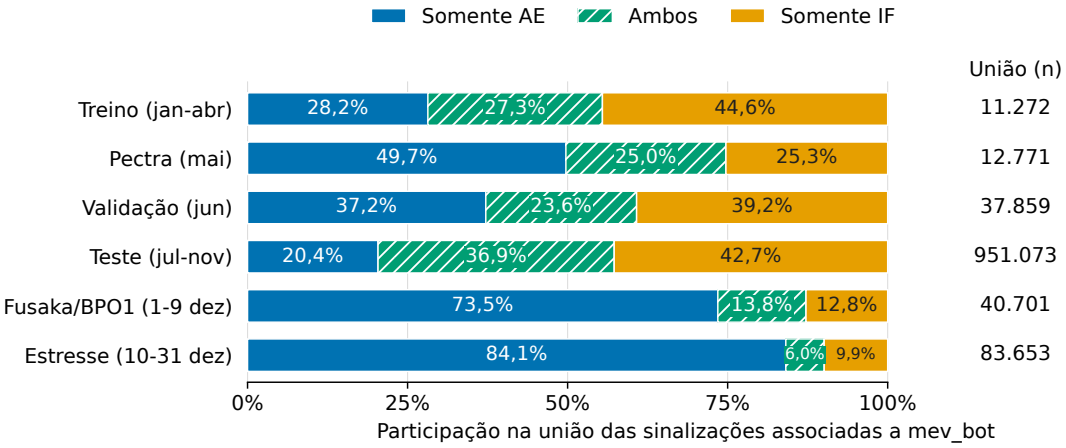


Figura 3. Composição das transações associadas a `mev_bot` sinalizadas em Q99,5. Cada barra corresponde à união associada do recorte; a coluna à direita informa sua quantidade absoluta.

A interseção oferece outra política de priorização: as 350.857 associadas representam 36,70% das 956.106 sinalizações compartilhadas no teste, frente a 12,95% no conjunto do AE e 29,61% no do IF. Sua concentração é aproximadamente 19,74 vezes a prevalência de 1,859% no recorte. A união aumenta a recuperação, enquanto a interseção reduz o volume e eleva a concentração da referência histórica. Esses números permitem dimensionar o ganho e o custo de combinar os modelos.

A composição varia entre regimes (Figura 3). No teste, 20,4% da união associada são exclusivos do AE, 36,9% compartilhados e 42,7% exclusivos do IF. No estresse, essas parcelas passam para 84,1%, 6,0% e 9,9%. O AE recuperou 75.354 associadas, contra 13.313 do IF; a união alcançou 83.653, ou 25,65% da referência do período. O IF acrescentou 8.299 associadas ao conjunto do AE, ganho de 11,01%. Nessa janela, a interseção concentrou 2,25% de associadas, abaixo dos 2,49% do AE isolado: concordância entre detectores não assegura maior concentração em todos os regimes.

Na transição de dezembro, o AE recuperou 35.508 associadas e o IF, 10.800, compartilhando 5.607; a união reuniu 40.701, com recall de 28,26%. As três janelas posteriores à calibração mostram, assim, contribuições distintas: o IF predomina entre as associadas exclusivas no teste, enquanto o AE predomina em dezembro. A combinação deve ser interpretada por período e pelo orçamento de investigação, e não como uma regra de superioridade invariável.

4.3. Ordenação global e orçamento de investigação

A Tabela 7 reúne ROC-AUC, AP e precision nos 1% maiores escores. O IF apresentou maior ROC-AUC e AP em todos os recortes. No teste, sua ROC-AUC foi 0,9481, contra 0,7690 do AE, e sua AP, 0,2067, contra 0,0866. Sob o mesmo orçamento de

Tabela 7. Ordenação dos escores frente à associação MEV. $P@1\%$ é a precision nos 1% maiores escores; Prev. é a prevalência (%).

		ROC-AUC		AP		$P@1\%$ (%)	
Recorte	Prev.	AE	IF	AE	IF	AE	IF
Treino	0,859	0,6432	0,9129	0,0128	0,0442	0,58	1,22
Pectra	1,028	0,7132	0,9210	0,0277	0,0633	4,29	4,12
Validação	1,273	0,8111	0,9421	0,1076	0,1219	19,87	15,79
Teste	1,859	0,7690	0,9481	0,0866	0,2067	8,17	29,26
Fusaka/BPO1	1,010	0,6189	0,9040	0,0329	0,0524	8,85	5,67
Estresse	0,876	0,6309	0,8822	0,0286	0,0349	7,12	1,71

2.410.204 transações, o IF priorizou 705.170 associadas e o AE, 196.885: precision de 29,26% e 8,17%, respectivamente. Os lifts foram 15,74 e 4,39 em relação à prevalência do período.

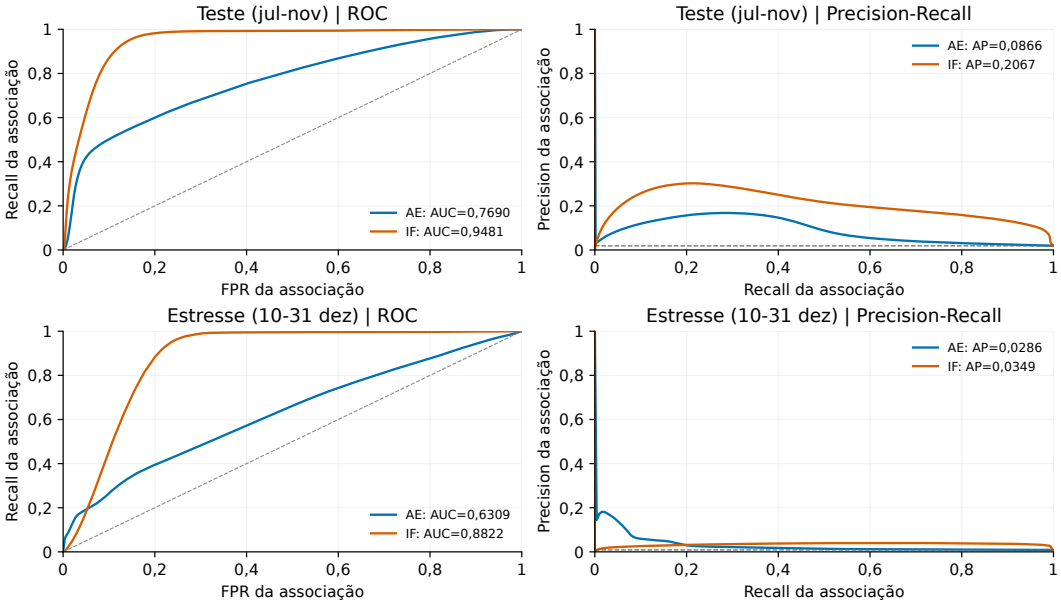


Figura 4. ROC e Precision-Recall no teste e no estresse. As linhas horizontais em Precision-Recall indicam a prevalência de cada recorte. ROC-AUC e AP são calculadas com todos os grupos de escores, antes da redução de pontos para apresentação.

No estresse, a AP do IF permaneceu superior (0,0349 frente a 0,0286), assim como a ROC-AUC (0,8822 frente a 0,6309). Entretanto, nos 1% maiores escores, o AE concentrou 7,12% de associadas, e o IF, 1,71%, para prevalência de 0,876%. O AE priorizou 26.492 associadas nesse orçamento, contra 6.371 do IF. A Figura 4 evidencia que as curvas Precision-Recall podem favorecer métodos diferentes em regiões distintas de recall. A AP resume a ordenação em seu conjunto; a precision sob orçamento fixo descreve uma decisão operacional específica.

A Figura 5 amplia essa comparação. No teste, o IF superou o AE nos quatro orçamentos, de 0,1% a 5%. No estresse, o AE apresentou maior concentração nos quatro:

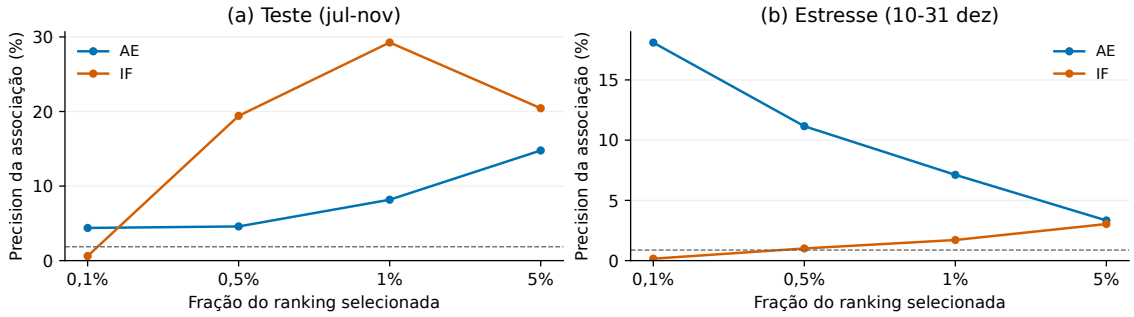


Figura 5. Precision da associação MEV em quatro orçamentos fixos do ranking. Linhas tracejadas indicam a prevalência. O mesmo percentual seleciona a mesma quantidade de transações para ambos os modelos em cada recorte.

nos 0,1% maiores escores, sua precision foi 18,10%, contra 0,16% do IF; nos 5%, foram 3,33% e 3,04%. A diferença reduz-se com a ampliação do conjunto investigado. A precision não cresce necessariamente quando o corte se torna mais extremo: no teste, o AE concentra 4,38% no topo de 0,1%, mas 14,77% no topo de 5%. Logo, escores mais extremos de anormalidade não precisam coincidir com maior concentração dessa categoria histórica.

Em conjunto, os resultados respondem às três questões do estudo: limiares fixos produzem expansão temporal distinta das sinalizações; a sobreposição é parcial e sua composição muda entre recortes; e a qualidade global da ordenação não determina, sozinha, o método mais adequado a um orçamento restrito. A análise de AP, precision, recall e parcelas exclusivas permite escolher entre concentração, recuperação e volume de investigação com critérios quantitativos comuns.

5. Conclusões e trabalhos futuros

A comparação de AE e IF em 523.937.952 transações da Ethereum mostrou que mecanismos distintos de anomalia geram conjuntos complementares e respostas temporais diferentes, mesmo com atributos e limiares de calibração comuns ao protocolo. Com hiperparâmetros preselecionados e novos ajustes em 2025, o IF apresentou maior AP em todos os recortes. No teste de julho a novembro, recuperou 757.192 transações associadas a bots MEV em Q99,5, frente às 544.738 do AE, com menor volume sinalizado. A interseção concentrou 36,70% de associadas entre 956.106 sinalizações, enquanto a união ampliou a recuperação para 951.073 associadas.

Em dezembro, o AE passou a contribuir com a maior parcela exclusiva da união associada. No estresse, recuperou 75.354 associadas em Q99,5, contra 13.313 do IF, e concentrou 7,12% no topo de 1%, frente a 1,71%. A AP do IF permaneceu maior nessa janela, distinguindo a ordenação global da concentração obtida sob um orçamento específico. Os achados sustentam a comparação por regime e por objetivo de investigação: interseção, união e ranking individual oferecem compromissos mensuráveis entre concentração, recuperação e esforço de análise.

Como continuidade, propomos adaptar os algoritmos de Torres et al. [Torres et al. 2021] ao contexto da Ethereum de 2025 para identificar candidatos a padrões de inserção, deslocamento e supressão. A geração estrutural será independente dos

escores e fornecerá uma referência comum para comparar a cobertura do AE, do IF e de suas sinalizações compartilhadas e exclusivas.

Os candidatos serão submetidos a avaliação semântica, articulando ordem transacional, chamadas de contratos, recibos, logs, rastros de execução e fluxos de ativos. A investigação examinará os papéis dos participantes e os efeitos econômicos, com simulações de cenários alternativos de execução quando pertinentes. Essa extensão permitirá validar padrões concretos de *front-running* e medir como cada política de priorização recupera eventos confirmados. A integração entre escores não supervisionados, detecção estrutural e evidência semântica amplia o uso dos resultados como instrumento de investigação da atividade transacional.

Referências

[Amazon Web Services 2026] Amazon Web Services (2026). AWS Public Blockchain Data. `https://registry.opendata.aws/aws-public-blockchain/`. Acesso em 17 out. 2026.

[Daian et al. 2020] Daian, P., Goldfeder, S., Kell, T., Li, Y., Zhao, X., Bentov, I., Breidenbach, L., and Juels, A. (2020). Flash boys 2.0: Frontrunning in decentralized exchanges, miner extractable value, and consensus instability. In *2020 IEEE Symposium on Security and Privacy*, pages 910–927. IEEE. DOI: 10.1109/SP40000.2020.00040.

[Eskandari et al. 2020] Eskandari, S., Moosavi, S., and Clark, J. (2020). SoK: Transparent dishonesty: Front-running attacks on blockchain. In *Financial Cryptography and Data Security*, volume 11599 of *Lecture Notes in Computer Science*, pages 170–189. Springer. DOI: 10.1007/978-3-030-43725-1_13.

[Ethereum Foundation 2025a] Ethereum Foundation (2025a). Fusaka mainnet announcement. `https://blog.ethereum.org/2025/11/06/fusaka-mainnet-announcement`. Acesso em 17 out. 2026.

[Ethereum Foundation 2025b] Ethereum Foundation (2025b). Pectra mainnet announcement. `https://blog.ethereum.org/2025/04/23/pectra-mainnet`. Acesso em 17 out. 2026.

[Etherscan 2021] Etherscan (2021). Public name tags, labels & public notes. `https://info.etherscan.com/public-name-tags-labels/`. Acesso em 17 out. 2026.

[Farrugia et al. 2020] Farrugia, S., Ellul, J., and Azzopardi, G. (2020). Detection of illicit accounts over the Ethereum blockchain. *Expert Systems with Applications*, 150:113318. DOI: 10.1016/j.eswa.2020.113318.

[Gama et al. 2014] Gama, J. a., Žliobaitė, I., Bifet, A., Pechenizkiy, M., and Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4):44:1–44:37. DOI: 10.1145/2523813.

[Heimbach et al. 2023] Heimbach, L., Kiffer, L., Torres, C. F., and Wattenhofer, R. (2023). Ethereum's proposer-builder separation: Promises and realities. In *Proceedings of the 2023 ACM Internet Measurement Conference*, pages 406–420. ACM. DOI: 10.1145/3618257.3624824.

[Li et al. 2024] Li, D., Zhang, K., Wang, L., and Du, G. (2024). A Geth-based real-time detection system for sandwich attacks in Ethereum. *Discover Computing*, 27(1):11. DOI: 10.1007/s10791-024-09445-6.

[Liu et al. 2008] Liu, F. T., Ting, K. M., and Zhou, Z.-H. (2008). Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining*, pages 413–422. IEEE. DOI: 10.1109/ICDM.2008.17.

[Podgorelec et al. 2020] Podgorelec, B., Turkanović, M., and Karakatič, S. (2020). A machine learning-based method for automated blockchain transaction signing including personalized anomaly detection. *Sensors*, 20(1):147. DOI: 10.3390/s20010147.

[Saito and Rehmsmeier 2015] Saito, T. and Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3):e0118432. DOI: 10.1371/journal.pone.0118432.

[Sakurada and Yairi 2014] Sakurada, M. and Yairi, T. (2014). Anomaly detection using autoencoders with nonlinear dimensionality reduction. In *Proceedings of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis*, pages 4–11. ACM. DOI: 10.1145/2689746.2689747.

[Torres et al. 2021] Torres, C. F., Camino, R., and State, R. (2021). Frontrunner jones and the raiders of the dark forest: An empirical study of frontrunning on the Ethereum blockchain. In *30th USENIX Security Symposium*, pages 1343–1359. USENIX Association.

[Zhang et al. 2024] Zhang, Y., Liu, P., Wang, G., Li, P., Gu, W., Chen, H., Liu, X., and Zhu, J. (2024). FRAD: Front-running attacks detection on Ethereum using ternary classification model. In *Ubiquitous Security*, volume 2034 of *Communications in Computer and Information Science*, pages 63–75. Springer. DOI: 10.1007/978-981-97-1274-8_5.